Introducción a Ciencia de Datos

Introducción a Machine Learning. Clasificación binaria

UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Introducción a Machine Learning

*Se dice que un programa de computadora aprende de la experiencia **E** con respecto a alguna tarea **T** y alguna medida de desempeño **P**...*

*Si su desempeño en **T**, medido por **P**, mejora con la experiencia **E***

Set de entrenamiento

Training set
(Experiencia)

- Instance / sample 1
- Instance / sample 2

...

- Instance / sample *n*

No confundir con "algoritmo"

Modelo
(Programa)

Como mido el desempeño?

Measure
(Desempeño)

UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Ejemplo

Tarea (T): **Filtro de Spam**, detectar nuevos emails que sean spam.

Conjunto de emails pasados o anteriores ya clasificados.

Training set
(E)

- email 1 → Es spam
- email 2 → No Spam
...
- email *n* → label *n*

Ejecutar tarea T de clasificar emails.

Modelo
(Programa)

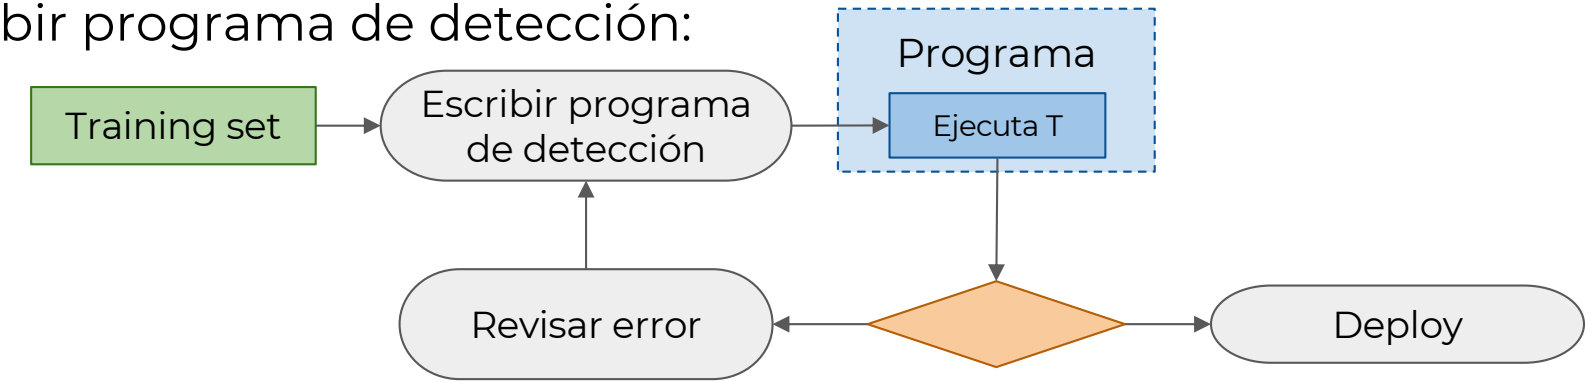
Evaluar qué tantos emails detectó correctamente del total.

Measure
(P)

UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Desarrollo tradicional de SW

1. Investigar el dataset con mails ya clasificados.
2. Identificar patrones comunes
3. Diseñar el pseudocódigo / lógica para identificar patrones del paso 2.
4. Escribir programa de detección:



1. Probar el programa, volviendo a paso 2 si no funciona correctamente.

UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Desarrollo tradicional de SW

Escribir programa de detección

Un embole

```
<?php
$tc=$_POST['tc'];
$ta=$_POST['ta'];
if ($tc=="e" && $ta=="a")
{$d=40;$ap="Efectivo, cheque o credito";}
else {if($tc=="e" && $ta=="b")
        {$d=30;$ap="Efectivo, cheque o credito";}
       else{if($tc=="e" && $ta=="c")
              {$d=20;$ap="Efectivo, cheque o credito";}
             else{if ($tc=="b" && $ta=="a")
                    {$d=30;$ap="Efectivo, cheque o credito";}
                   else {if($tc=="b" && $ta=="b")
                          {$d=20;$ap="Efectivo, cheque o credito";}
                         else{if($tc=="b" && $ta=="c")
                                {$d=10;$ap="Efectivo, cheque o credito";}
                               else{if ($tc=="r" && $ta=="a")
                                      {$d=20;$ap="Efectivo, cheque";}
                                     else {if($tc=="r" && $ta=="b")
                                            {$d=10;$ap="Efectivo, cheque";}
                                           else{if($tc=="r" && $ta=="c")
                                                  {$d=0;$ap="Efectivo, cheque";}
                                                 else{if ($tc=="m" && $ta=="a")
                                                        {$d=0;$ap="Efectivo";}
                                                       else {if($tc=="m" && $ta=="b")
                                                              {$d=0;$ap="Efectivo";}
                                                             else{if($tc=="m" && $ta=="c")
                                                                    {$d=0;$ap="Efectivo";}
                                                                  }
                                                           }
                                                  }
                                           }
                                    }
                             }
                    }
             }
      }
```

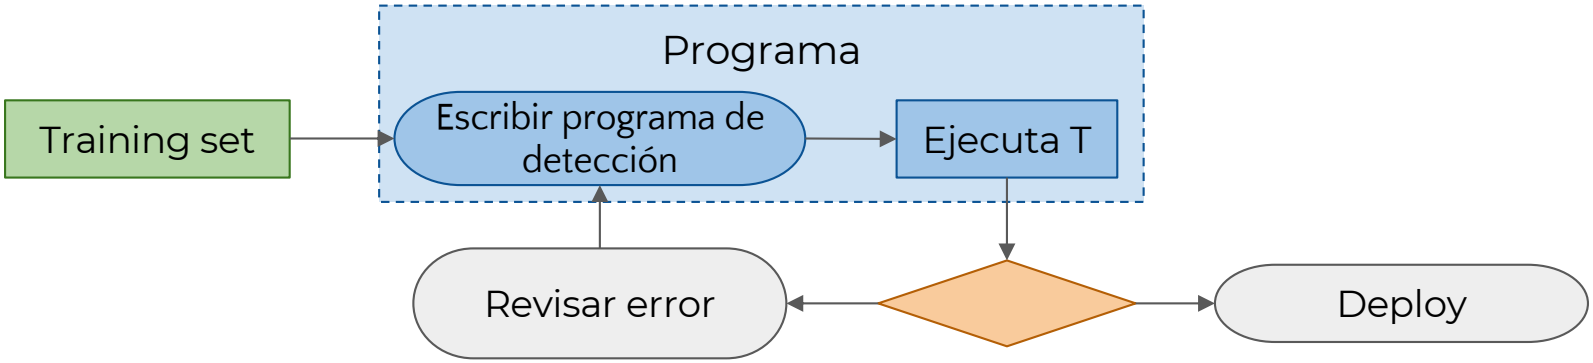
	A	B	C	D	E	F	G	H	I	J
1	State	Product Segment	Customer Age		Veh Age	Vehicle Rate Group	Driving Record	COVERAGE	Product Option	Value
2					*	1	*	Liability	Economy	$1,500,000
3		Green	*		*	1	*	Liability	Standard	$1,500,000
4					*	1	*	Liability	Plus	$1,500,000
5					*	1	*	Liability	Economy	$1,500,000
6		Red	< 25		*	1	*	Liability	Standard	$1,500,000
7					*	1	*	Liability	Plus	$1,500,000
8					*	1	*	Liability	Economy	$1,500,000
9		Yellow	< 25		*	1	*	Liability	Standard	$1,500,000
10					*	1	*	Liability	Plus	$1,500,000
11					*	1	*	Liability	Economy	$1,500,000
12		Red	>= 25	<40	*	1	*	Liability	Standard	$1,500,000
13					*	1	*	Liability	Plus	$2,000,000
14					*	1	*	Liability	Economy	$1,500,000
15		Yellow	>= 25		*	1	*	Liability	Standard	$1,500,000
16					*	1	*	Liability	Plus	$2,000,000
17					*	1	*	Liability	Economy	$1,500,000
18		Red			*	1	*	Liability	Standard	$2,000,000
19					*	1	*	Liability		
20					*	1	*	Liability		
21		Yellow			*	1	*	Liability		
22					*	1	*	Liability		
23					*	1	*	Liability		
24		Green			*	1	*	Liability		
25					*	1	*	Liability		
26					*	1	*	Liability		
27	NY	Red			*	1	*	Liability		
28					*	1	*	Liability		
29					*	1	*	Liability		
30		Yellow			*	1	*	Liability		
31					*	1	*	Liability		
32					*	1	*	Liability		
33		Red	>= 25	<40	*	1	*	Liability		
34					*	1	*			
35					*	1	*	Family Protection		
36		Yellow	>= 25	<40	*	1	*	Family Protection	Standard	$1,500,000
37					*	1	*	Family Protection	Plus	$2,000,000
38					*	1	*	Family Protection	Economy	$1,500,000

Assesment date		Insured Value		Additional Premium
>=2016-01-01	<2016-12-31	>=0	<12000	0
		>=12000	<24000	1.45
		>=24000	<36000	2
		>=36000	<48000	2.22
		>=48000		3
>=2015-01-01	<2015-12-31	>=0	<12000	0
		>=12000	<24000	1.6
		>=24000	<36000	2.1
		>=36000	<48000	2.4
		>=48000		3.3
>=2014-01-01	<2014-12-31	>=0	<12000	0
		>=12000	<24000	1.8
		>=24000	<36000	2.25
		>=36000	<48000	2.64
		>=48000		3.55

UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Desarrollo ML

Modelo o programa SW es quien define las reglas de dirección:



Programas:

- Más cortos.
- Fáciles de mantener.
- Adaptables al cambio.

UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Entrenamiento del modelo

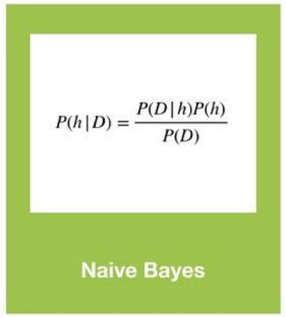
Existen **diversos** algoritmos**.**

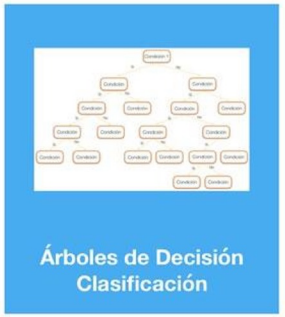
Generalizar los datos**:** Buscar los **parámetros** del modelo **óptimos**.









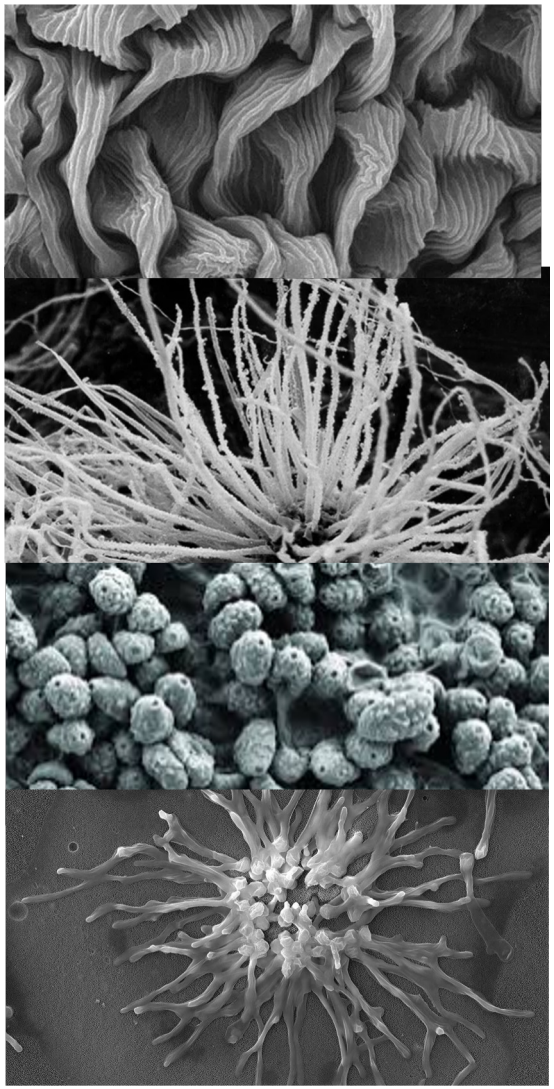




Ya vamos a verlos...

Buenos para...

1. Situaciones donde la **lógica** de programa se vuelve **demasiado compleja o imposible** para programar y mantener de forma tradicional.
2. Patrones **cambiantes en el tiempo**.
3. Extraer patrones y conocimiento de **datos complejos y con gran volumen**.



Librería Machine Learning



- Herramientas simple para **machine learning**, data mining y análisis de datos:
  - Limpieza y preproceso de datos.
  - Algoritmos de *clasificación*, *regresión*, *clusterización* entre otros.
  - Validación y medición de performance.
- Construida sobre **NumPy**, SciPy.

- Proyecto Open source, licencia BSD.
- http://scikit-learn.org/

Clasificación de algoritmos

1. **Tipo de tarea (T) que resuelve:**
   Clasificación, Regresión, Clusterización, Reducción de Dimensiones, Asociación...

2. Forma de generalizar a nuevos datos

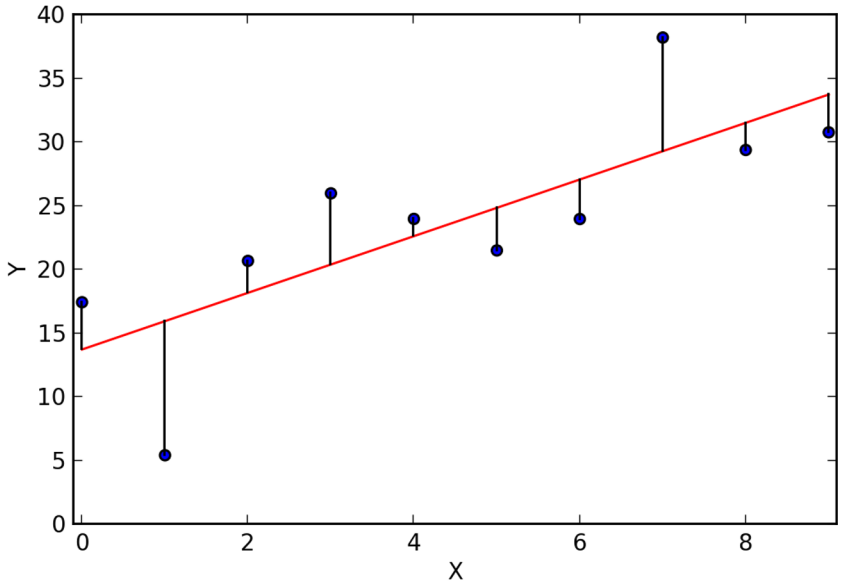
3. Aprendizaje incremental vs batch.

4. **Supervisión del aprendizaje:**
   Supervisado, No supervisado, Reforzado

Los criterios no son excluyentes.

Clasificación de algoritmos por tipo de tarea

Regresión



Busca predecir un **valor cuantitativo**, por ejemplo el precio de venta de una casa, el valor de una acción, una temperatura, etc.

UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Clasificación

1. Dividir en grupos predefinidos o categorías (categorial labels).
2. Datos de entrenamiento para los cuales se conoce a qué grupo pertenecen.
3. Modelo es entrenado y luego predice a qué grupo pertenecen nuevos elementos.
4. Algunos usos:
    - Identificar transacciones fraudulentas.
    - Categorizar clientes riesgosos.

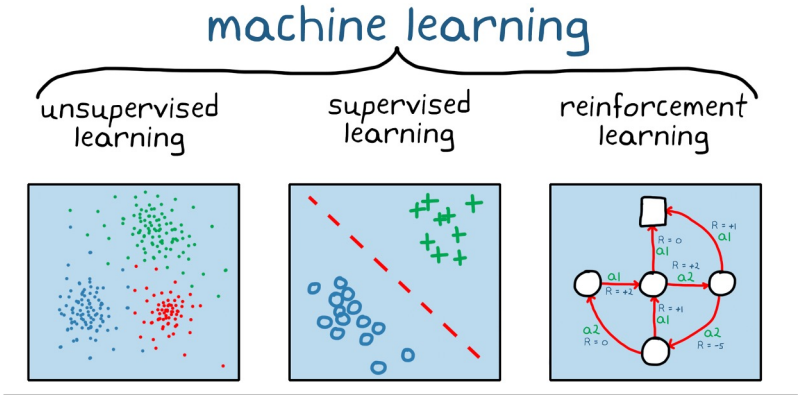


Clasificación de algoritmos por tipo de aprendizaje

Clasificación de algoritmos por tipo de aprendizaje

Los algoritmos de machine learning se clasifican según el tipo de aprendizaje que implementan:

- Supervisado
- No supervisado
- Reforzado



UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

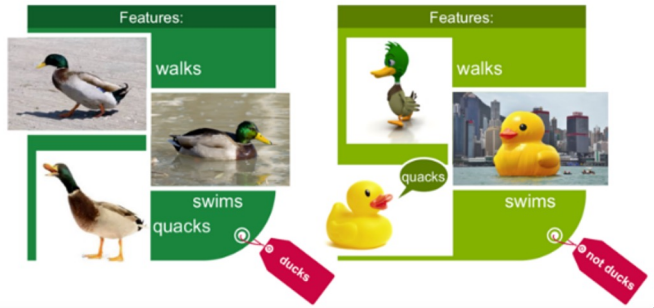
Aprendizaje Supervisado

Data Scientist actúa como guía para enseñarle al algoritmo.

- **Labeled data** (Datos de ejemplos para el alg.)
  Muestra *N* + Resultado deseado *N*
- Uso: **Predecir un valor**.
- Más usado.
- Tipos de tareas:
  - **Clasificación** (predecir una clase/discreto)
    - Clasificar correos como spam o no spam
  - **Regresión** (predecir un valor continuo)
    - Ej: Predecir el precio de una casa

Algoritmos:

- k-Nearest Neighbors
- *Regresión Lineal*
- *SVMs*
- *Árboles de decisión*
- Algunas redes Neuronales



UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Aprendizaje No Supervisado

Identificar patrones sin ayuda humana.

- **Unlabeled data**:
  Muestra *N*
- Uso: **Encontrar relaciones/patrones**.
- Más difíciles de evaluar y entender.
- Tipos de tareas:
  - **Clustering**
    - Ej: Agrupar clientes según su comportamiento de compra
  - **Reglas de asociación**
  - **Visualización & Dimension Reduction**

Algoritmos:

- K-Means
- Principal Component Analysis

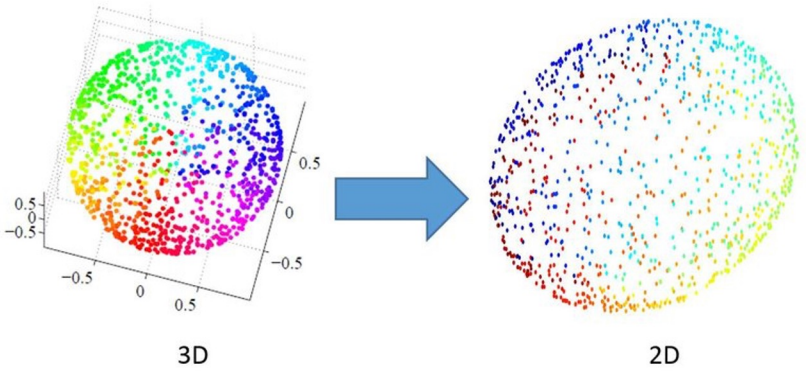


UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Aprendizaje No supervisado

Visualización & Dimensional reduction: Preservar características, reduciendo dimensiones.

- Entrenamientos más veloces
- Menores requerimientos de espacio.
- Mejores resultados.
- Algoritmos limitados por cantidad de dimensiones.



UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Aprendizaje No supervisado

Visualización & Dimensional reduction: Preservar características, reduciendo dimensiones.

Ejemplo:

Reconocer la actividad de una persona:
- Caminando, Parado, Sentado, Acostado, Subiendo escaleras, Bajando escaleras.

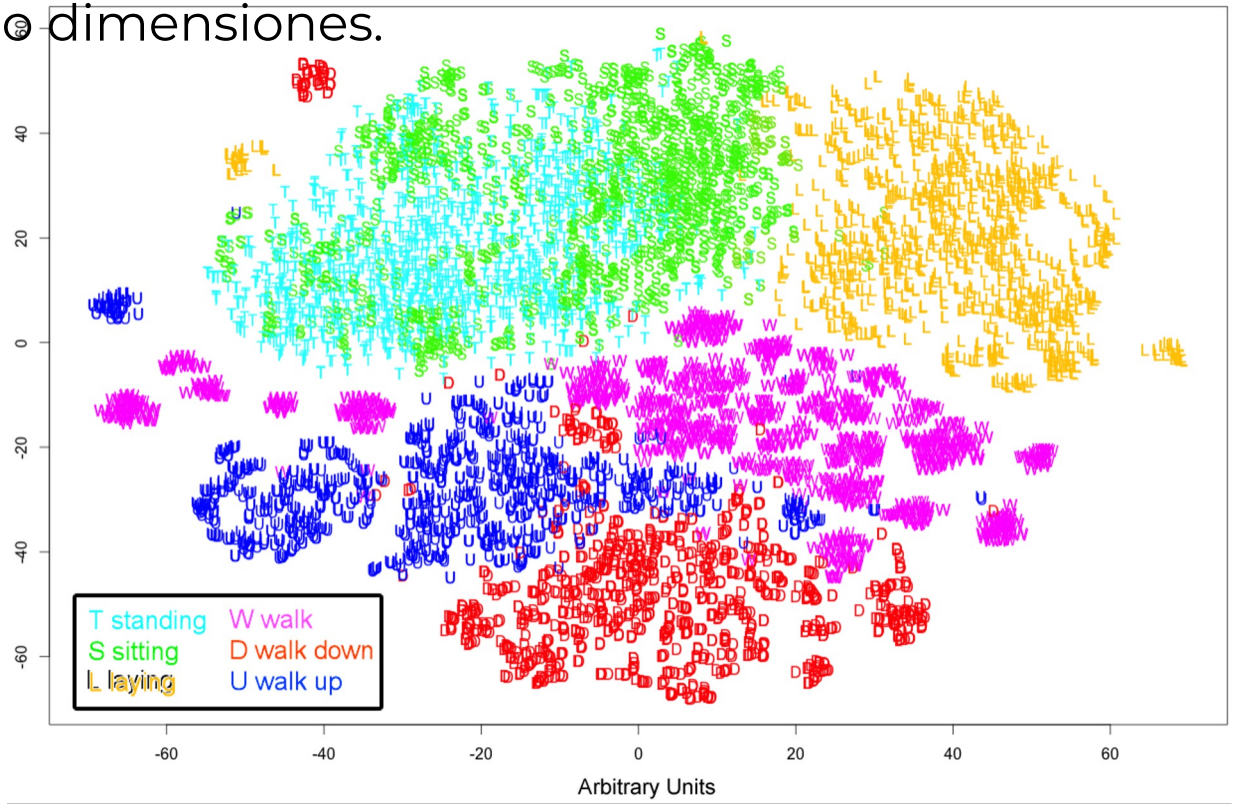
Input:
- 7352 samples de 30 individuos.
- Sample con 561 atributos o dimensiones.

Output:

Gráfico para explorar visualmente.

Aprendizaje No supervisado

Visualización & Dimensional reduction: Preservar características, reduciendo dimensiones.

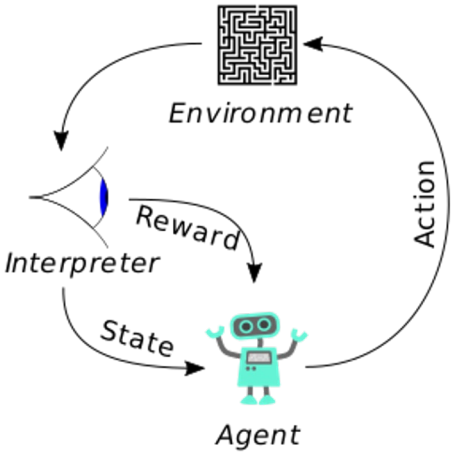


UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Aprendizaje Reforzado

Algoritmo aprende en base a las acciones que realiza.

- Aprende de **recompensas** y **penalidades**.
- Uso: **Predecir la mejor acción a tomar**.
- Aprende a lo largo de intentos/tiempo.
- Estados y acciones
- Función de Recompensa: F(a,e) = reward



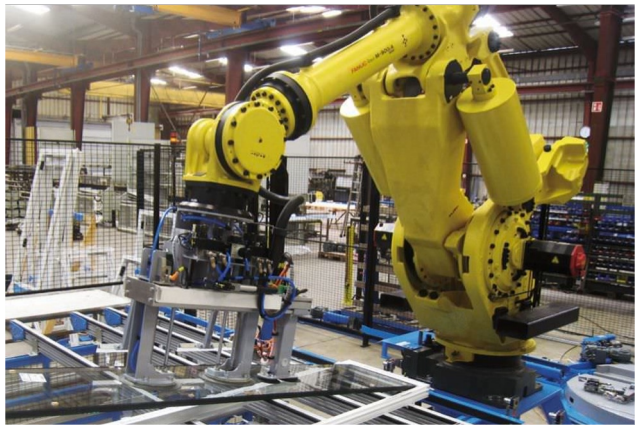
UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Aprendizaje Reforzado

Casos de Uso/Áreas:

- Vehículos autónomos.
- Juegos de estrategia (Go, Ajedrez).
- Robótica.





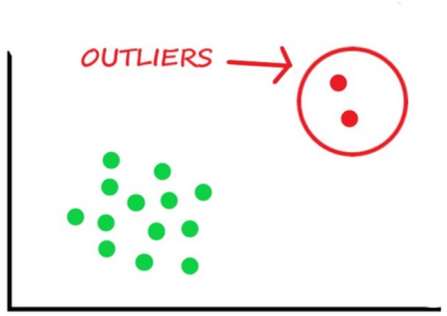
Desafíos & problemas

Principales problemas

1. Calidad & cantidad de datos
2. Ruido
3. Outliers
4. Valores faltantes
5. Falta de estandarización
6. Complejidad del Modelo vs. Tamaño del Dataset.

Principales problemas

1. Calidad & cantidad de datos
2. Ruido
3. Outliers
4. Valores faltantes
5. Falta de estandarización
6. Complejidad del Modelo vs. Tamaño del Dataset.



Principales problemas

Features Irrelevantes

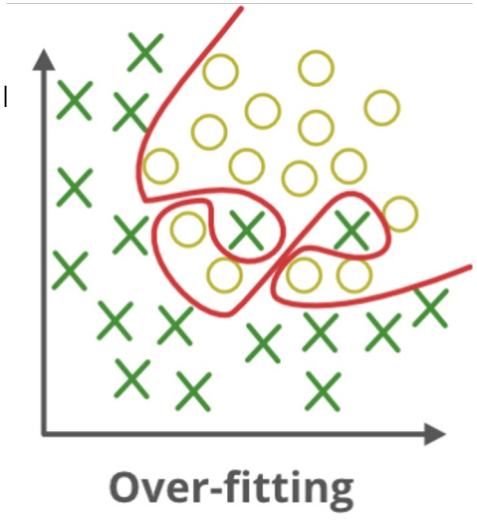
- Cantidad de features disponibles y relevancia.
- **Menos** features **irrelevantes**, **más** features **relevantes**
  -> mejor **performance**.
- **Feature Engineering**:
  - Feature selection
  - Feature extraction
  - New features



Principales problemas

Generalización: Overfitting

- Algoritmo **aprende de memoria** -> Mala generalizació
- Mayor susceptibilidad en **modelos complejos**.
- Buscar balance:
  - Complejidad del modelo usado & regularización.
  - Patrones a detectar vs. ruido en los datos.
  - Cantidad de datos.



Algoritmos de ML se basan en inferencia de los datos.

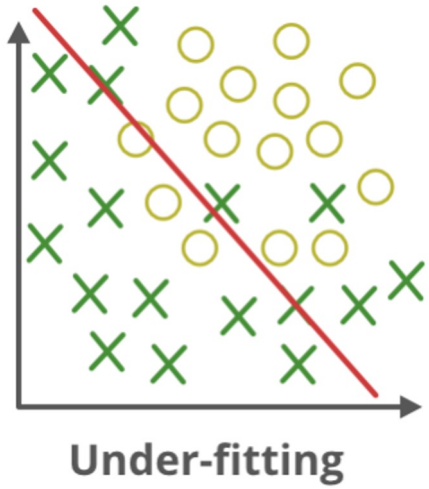
Esta curva se llama frontera de decisión, despues la vemos en más detalle...

UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Principales problemas

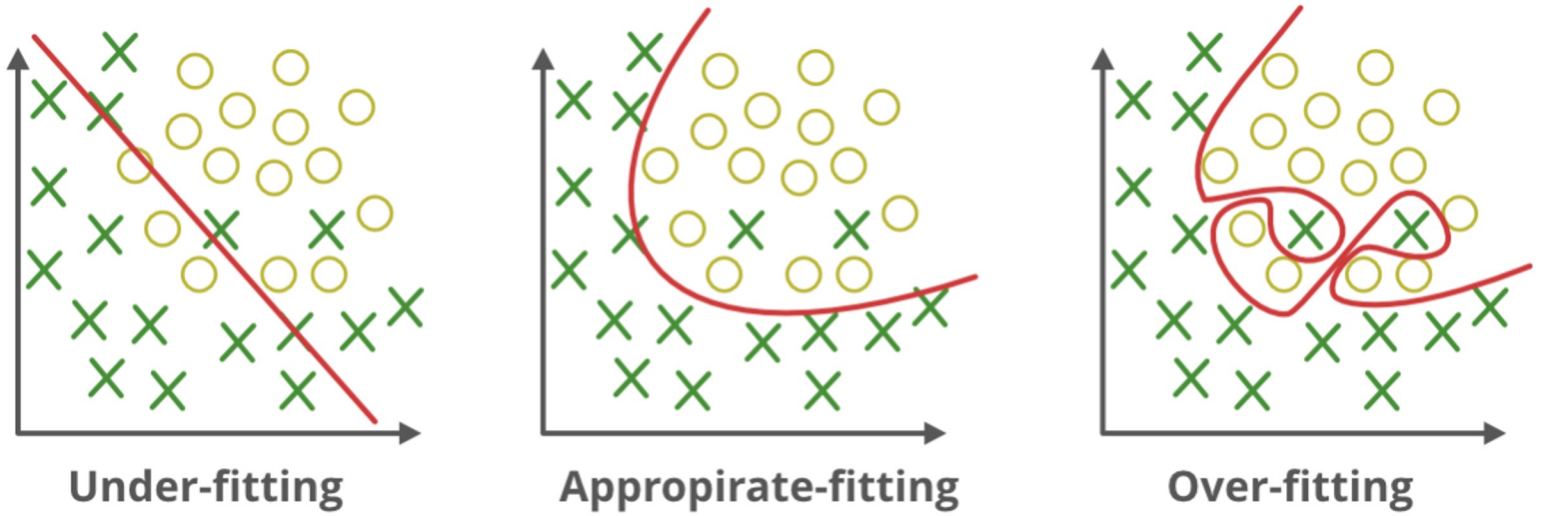
Generalización: Underfitting

- Modelo demasiado simple para la naturaleza de los datos.
- Buscar:
  - Modelo más poderoso
  - Feature Engineering
  - Reducir restricciones del modelo.



UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Principales problemas



Queremos estar acá...

Aprendizaje supervisado: Clasificación Binaria

Clasificación binaria

- Es un tipo de problema en el que las observaciones se **agrupan** en una de **dos clases posibles**. Cada predicción realizada por el modelo es una **decisión entre dos opciones**.
- La clasificación binaria es útil en muchos ámbitos. Ejemplos:
  - Detección de correos spam (Spam / No Spam)
  - Diagnóstico médico (Enfermo / No enfermo)
  - Detección de fraude (Transacción legítima / fraudulenta)
  - Clasificación de imágenes (Perro / Gato)
  - Clasificación de noticias (Noticia verídica / fake news)
  - Predicción de lluvias (Hoy llueve/ no llueve)

UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Pipeline de Clasificación Binaria

Proceso típico para resolver problemas de clasificación binaria:

- **Recolección de datos:** Obtener un dataset con características que permitan hacer predicciones (por ejemplo, edad, ingresos).
- **Preprocesamiento:**
  - Limpieza de datos (ej: eliminar datos faltantes)
  - Codificación de variables categóricas (ej: convertir “masculino/femenino” a 0/1).
- **División del conjunto de datos:** Separar los datos en conjunto de entrenamiento y conjunto de prueba (ej: 80%-20%).
- **Entrenamiento del modelo:** Aplicar un algoritmo de clasificación binaria (Ej: Árbol de decisión)
- **Evaluación:** Medir el rendimiento del modelo usando métricas (Ej: precisión o recall)

UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

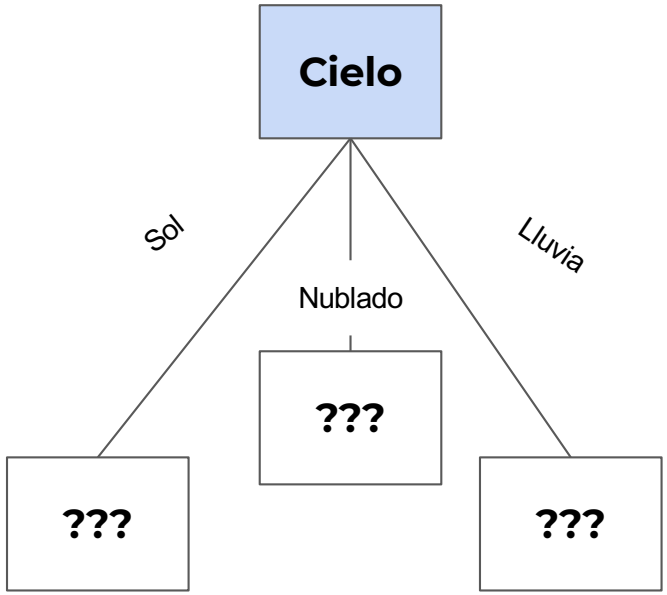
Árbol de Decisión

Uno de los modelos más simples y poderosos



- Modelo predictivo que representa decisiones y sus posibles consecuencias en una estructura de árbol.
- Divide el conjunto de datos en subconjuntos más pequeños basados en características y valores de los datos
- Utilizado en clasificación y regresión, donde se busca predecir una clase o valor.

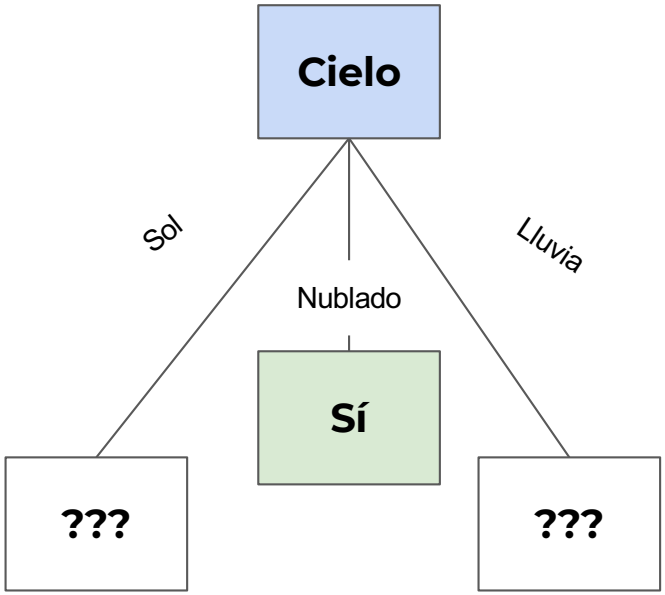
Cómo se arma un Árbol de Decisión



Qué clima tiene que haber para que Juan salga a caminar?

Cielo	Temperatura	Humedad	Viento	¿Camina?
Sol	Calor	Alta	Débil	No
Sol	Calor	Alta	Fuerte	No
Nublado	Calor	Alta	Débil	Sí
Lluvia	Templado	Alta	Débil	Sí
Lluvia	Frío	Normal	Débil	Sí
Lluvia	Frío	Normal	Fuerte	No
Nublado	Frío	Normal	Fuerte	Sí
Sol	Templado	Alta	Débil	No
Sol	Frío	Normal	Débil	Sí
Lluvia	Templado	Normal	Débil	Sí
Sol	Templado	Normal	Fuerte	Sí
Nublado	Templado	Alta	Fuerte	Sí
Nublado	Calor	Normal	Débil	Sí
Lluvia	Templado	Alta	Fuerte	No

Cómo se arma un Árbol de Decisión

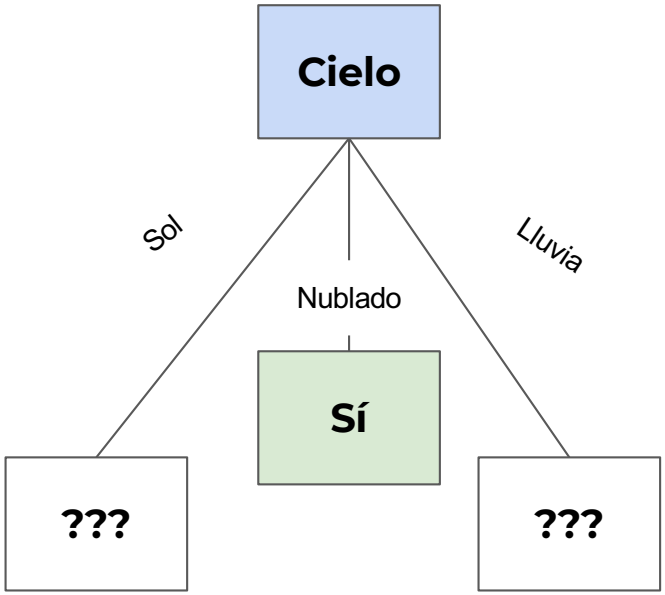


Qué clima tiene que haber para que Juan salga a caminar?

Cielo	Temperatura	Humedad	Viento	¿Camina?
Sol	Calor	Alta	Débil	No
Sol	Calor	Alta	Fuerte	No
Nublado	Calor	Alta	Débil	Sí
Lluvia	Templado	Alta	Débil	Sí
Lluvia	Frío	Normal	Débil	Sí
Lluvia	Frío	Normal	Fuerte	No
Nublado	Frío	Normal	Fuerte	Sí
Sol	Templado	Alta	Débil	No
Sol	Frío	Normal	Débil	Sí
Lluvia	Templado	Normal	Débil	Sí
Sol	Templado	Normal	Fuerte	Sí
Nublado	Templado	Alta	Fuerte	Sí
Nublado	Calor	Normal	Débil	Sí
Lluvia	Templado	Alta	Fuerte	No

UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Cómo se arma un Árbol de Decisión

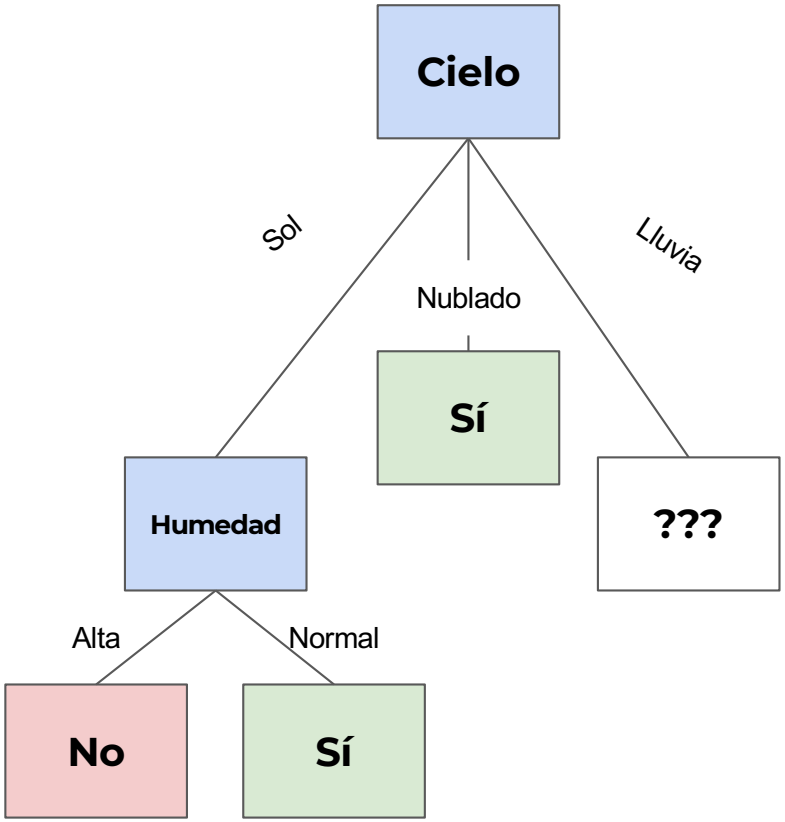


Qué clima tiene que haber para que Juan salga a caminar?

Cielo	Temperatura	Humedad	Viento	¿Camina?
Sol	Calor	Alta	Débil	No
Sol	Calor	Alta	Fuerte	No
Nublado	Calor	Alta	Débil	Sí
Lluvia	Templado	Alta	Débil	Sí
Lluvia	Frío	Normal	Débil	Sí
Lluvia	Frío	Normal	Fuerte	No
Nublado	Frío	Normal	Fuerte	Sí
Sol	Templado	Alta	Débil	No
Sol	Frío	Normal	Débil	Sí
Lluvia	Templado	Normal	Débil	Sí
Sol	Templado	Normal	Fuerte	Sí
Nublado	Templado	Alta	Fuerte	Sí
Nublado	Calor	Normal	Débil	Sí
Lluvia	Templado	Alta	Fuerte	No

UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Cómo se arma un Árbol de Decisión

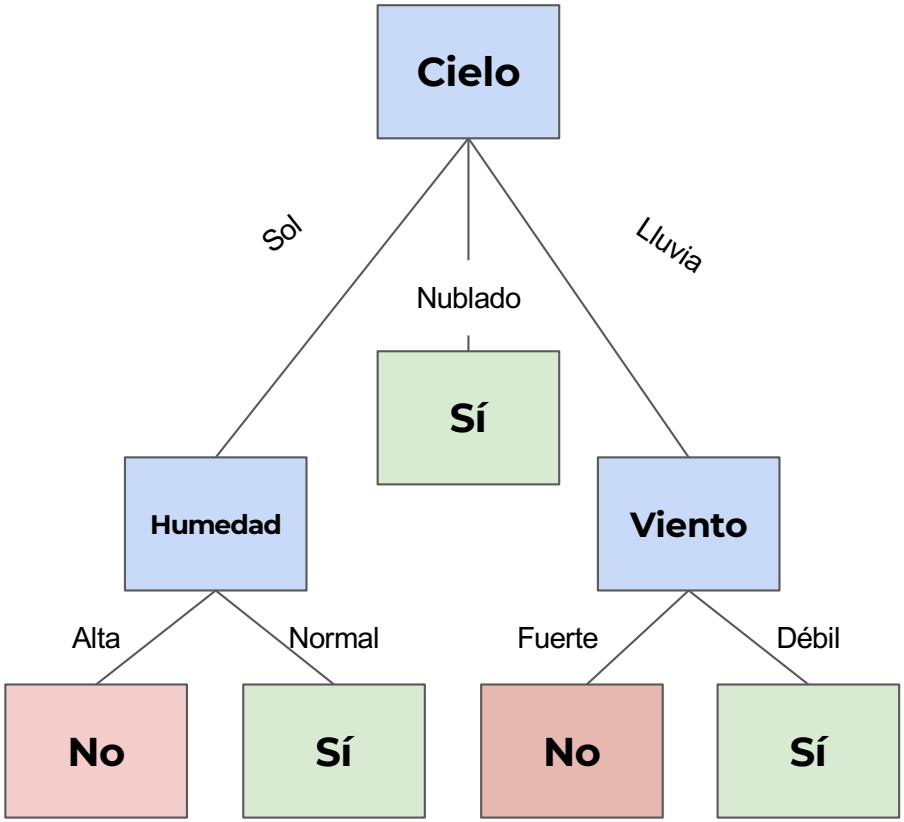


Qué clima tiene que haber para que Juan salga a caminar?

Cielo	Temperatura	Humedad	Viento	¿Camina?
Sol	Calor	Alta	Débil	No
Sol	Calor	Alta	Fuerte	No
Nublado	Calor	Alta	Débil	Sí
Lluvia	Templado	Alta	Débil	Sí
Lluvia	Frío	Normal	Débil	Sí
Lluvia	Frío	Normal	Fuerte	No
Nublado	Frío	Normal	Fuerte	Sí
Sol	Templado	Alta	Débil	No
Sol	Frío	Normal	Débil	Sí
Lluvia	Templado	Normal	Débil	Sí
Sol	Templado	Normal	Fuerte	Sí
Nublado	Templado	Alta	Fuerte	Sí
Nublado	Calor	Normal	Débil	Sí
Lluvia	Templado	Alta	Fuerte	No

UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Cómo se arma un Árbol de Decisión

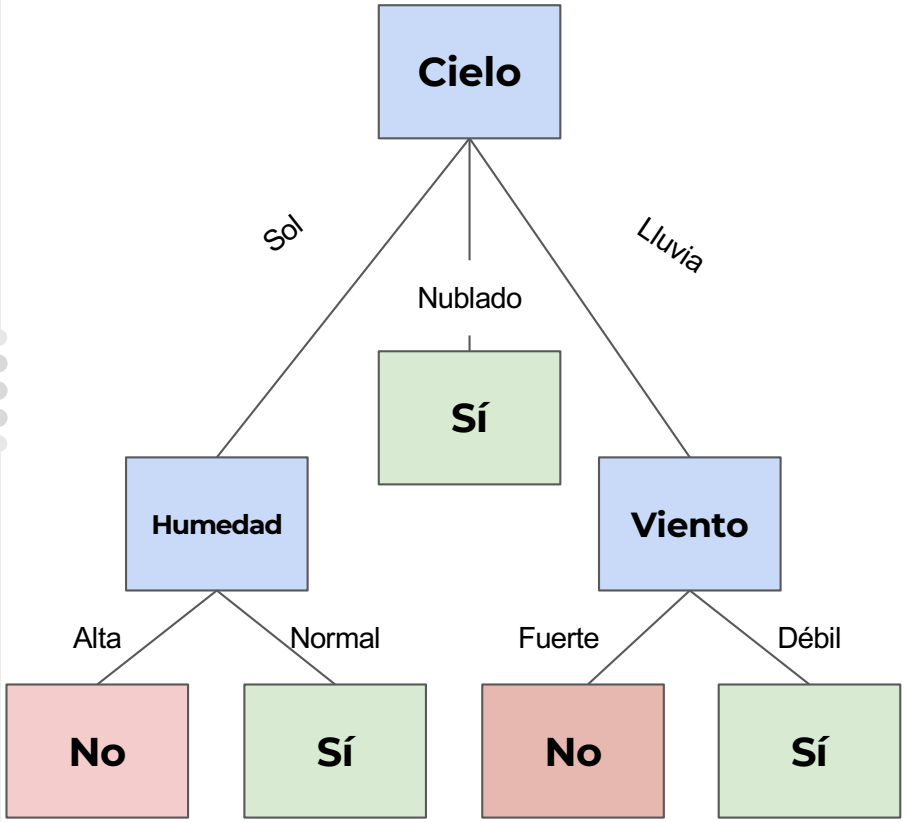


Qué clima tiene que haber para que Juan salga a caminar?

Cielo	Temperatura	Humedad	Viento	¿Camina?
Sol	Calor	Alta	Débil	No
Sol	Calor	Alta	Fuerte	No
Nublado	Calor	Alta	Débil	Sí
Lluvia	Templado	Alta	Débil	Sí
Lluvia	Frío	Normal	Débil	Sí
Lluvia	Frío	Normal	Fuerte	No
Nublado	Frío	Normal	Fuerte	Sí
Sol	Templado	Alta	Débil	No
Sol	Frío	Normal	Débil	Sí
Lluvia	Templado	Normal	Débil	Sí
Sol	Templado	Normal	Fuerte	Sí
Nublado	Templado	Alta	Fuerte	Sí
Nublado	Calor	Normal	Débil	Sí
Lluvia	Templado	Alta	Fuerte	No

UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Cómo se arma un Árbol de Decisión



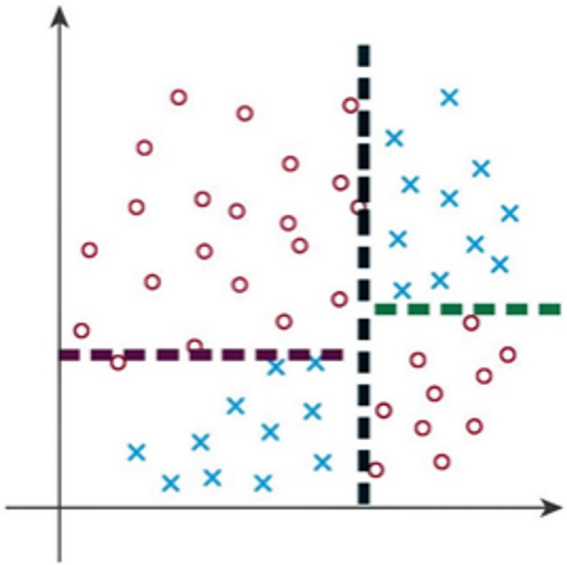
Cielo	Temperatura	Humedad	Viento	¿Camina?
Sol	Calor	Alta	Débil	No
Sol	Calor	Alta	Fuerte	No
Nublado	Calor	Alta	Débil	Sí
Lluvia	Templado	Alta	Débil	Sí
Lluvia	Frío	Normal	Débil	Sí
Lluvia	Frío	Normal	Fuerte	No
Nublado	Frío	Normal	Fuerte	Sí
Sol	Templado	Alta	Débil	No
Sol	Frío	Normal	Débil	Sí
Lluvia	Templado	Normal	Débil	Sí
Sol	Templado	Normal	Fuerte	Sí
Nublado	Templado	Alta	Fuerte	Sí
Nublado	Calor	Normal	Débil	Sí
Lluvia	Templado	Alta	Fuerte	No

Se les ocurre algun hiperparámetro?

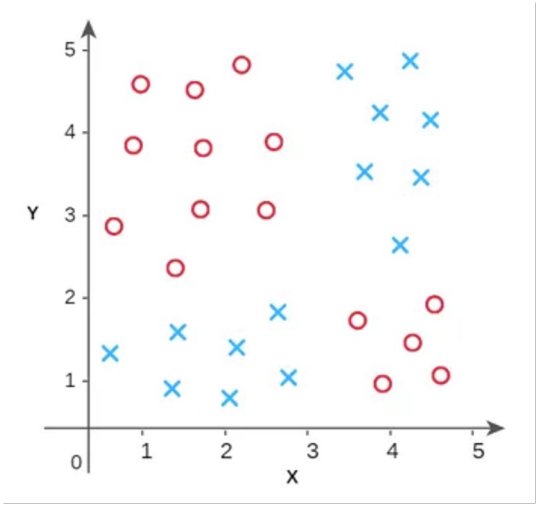
UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Frontera de decisión

- Línea o superficie que separa las diferentes clases en un modelo de clasificación
- En Árbol de Decisión, la frontera de decisión es generada por las divisiones en cada nodo del árbol, creando regiones rectangulares o cuadradas en un espacio de características



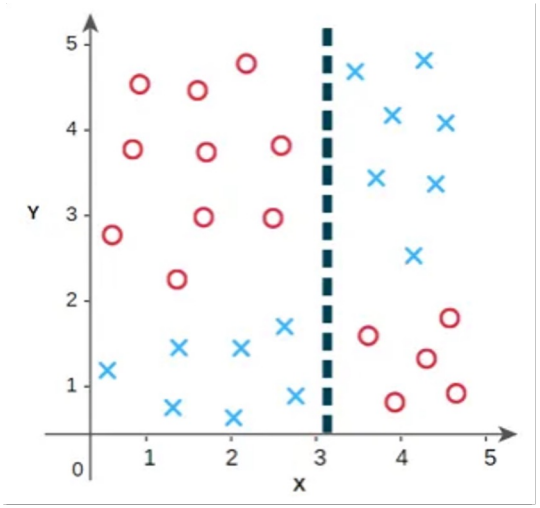
Frontera de decisión



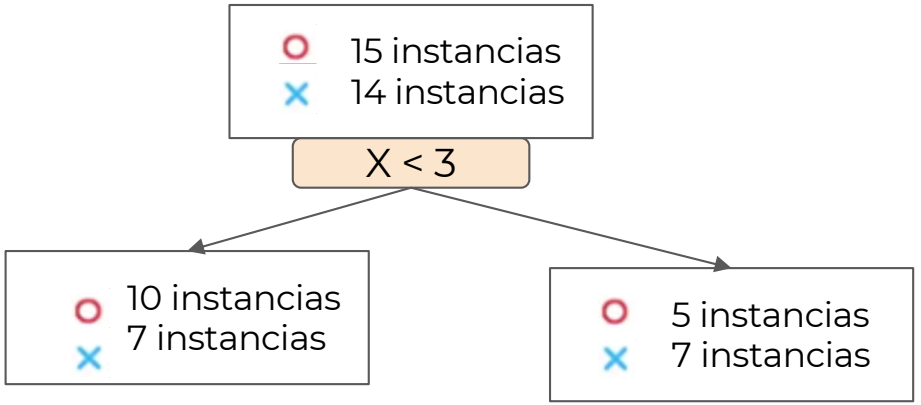
Nodos:

15 instancias
14 instancias

Frontera de decisión

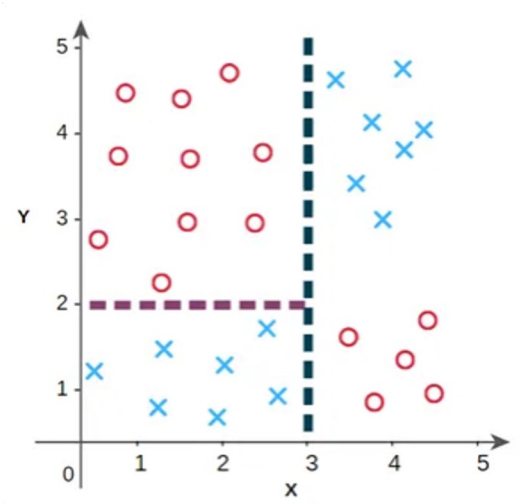


Nodos:

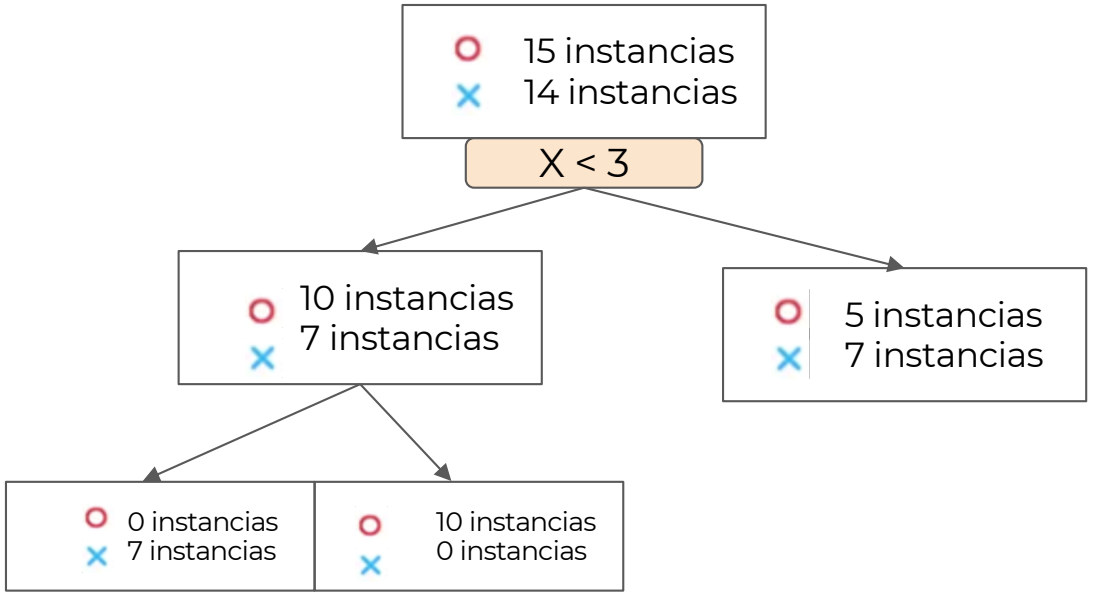


UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Frontera de decisión

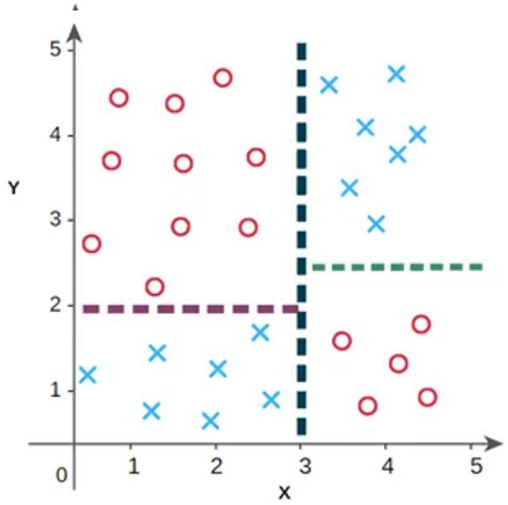


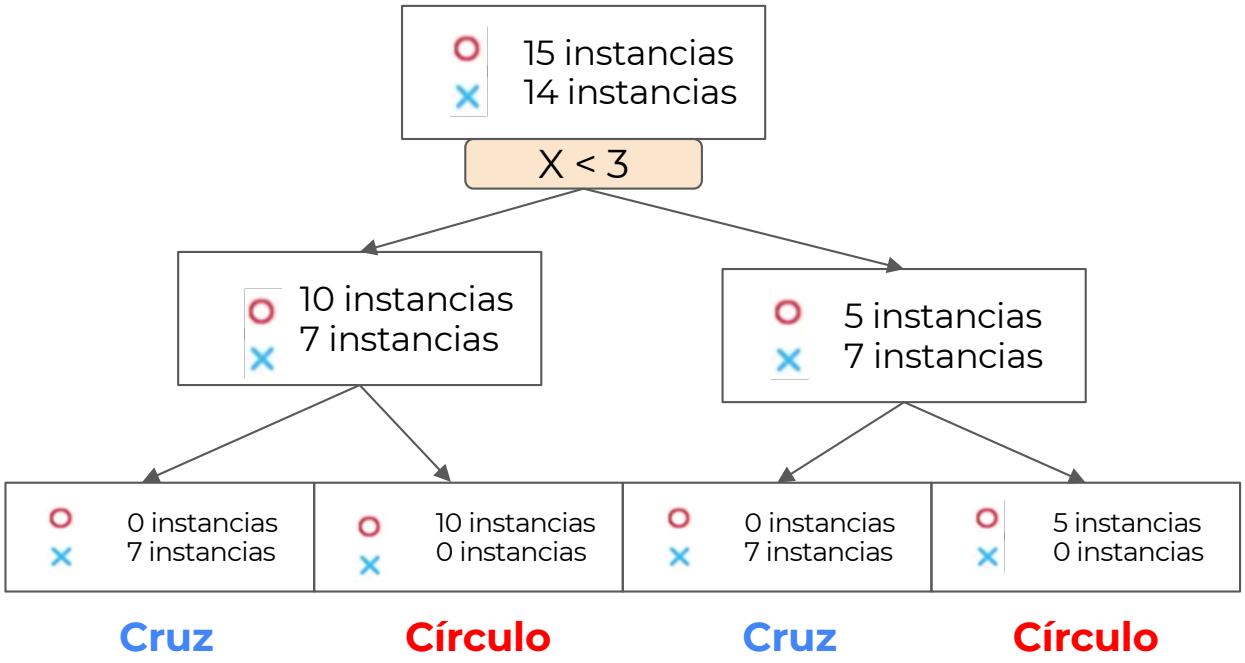
Nodos:



UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

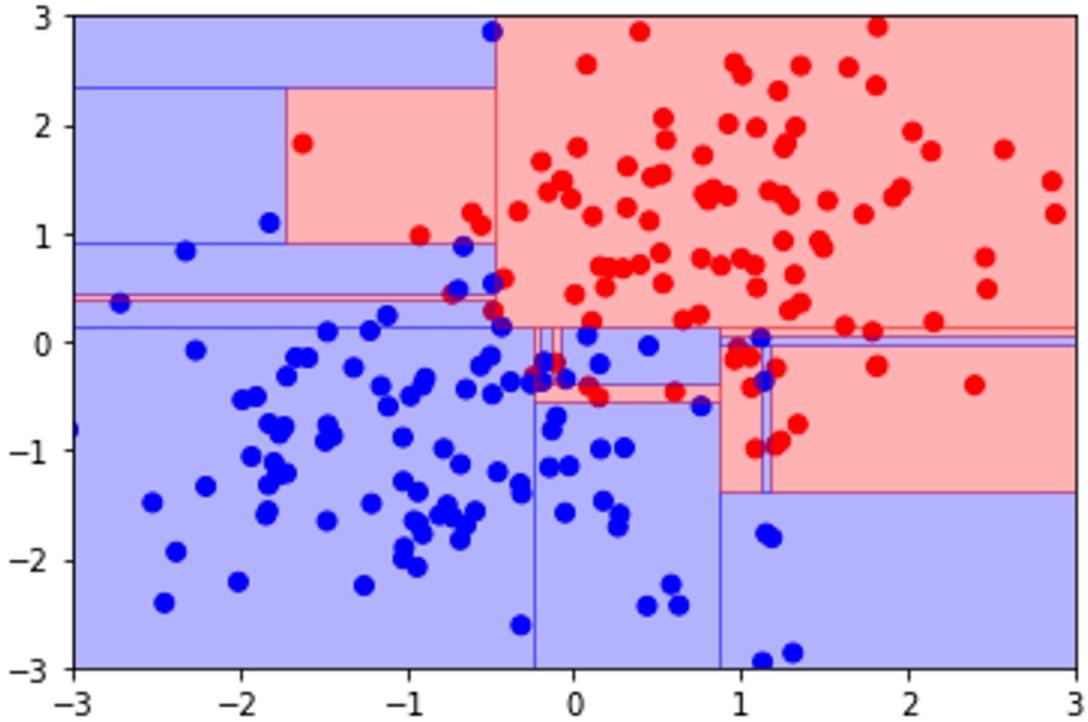
Frontera de decisión





UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Frontera de decisión de un Árbol de decisión



En árboles binarios para atributos continuos:

- Forma jerárquica (cada región se divide en exactamente 2 regiones o ninguna)
- Rectangulares
- Cada hoja representa una región del espacio de características donde se asigna una etiqueta de clase.

UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Accuracy

- **Proporción de predicciones correctas** sobre el total de predicciones.

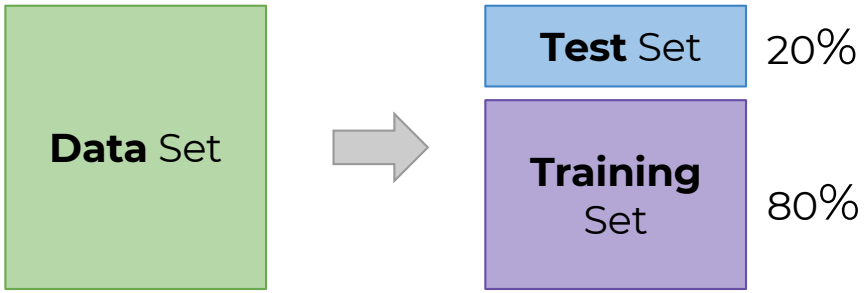
$$A_{(modelo)} = \frac{\text{Predicciones Correctas}}{\text{Cantidad de predicciones}}$$



Métrica muy sencilla pero con muchos problemas, ideal para arrancar. La siguiente clase seguimos viendo otras

Train Test Split

- Separar parte de los datos en el **Test Set**.
  Lo utilizaremos para **evaluar qué tan bien performa el modelo** antes de su puesta en producción.
- Existen **diferente estrategias**:
  - **Random**: Tomar 20% de las muestras/observaciones al azar.

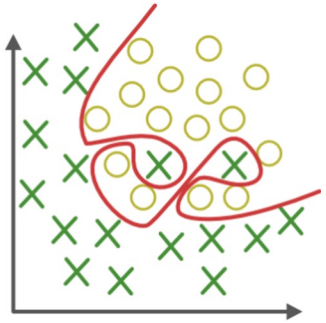


Train Test Split

Comprobar predicciones del modelo:

Opción A: Puesta de Producción.

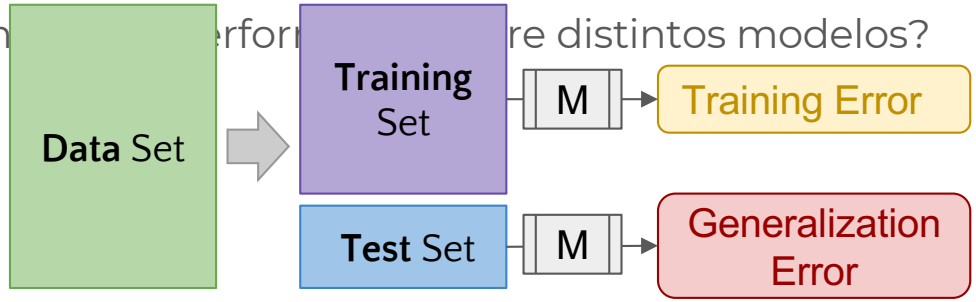
Opción B: Utilizando **Test Set**.



Training Error Bajo, Generalization Error Alto -> **Overfitting**

¿Cómo corregir y ajustar el modelo?

¿Cómo com erfor re distintos modelos?



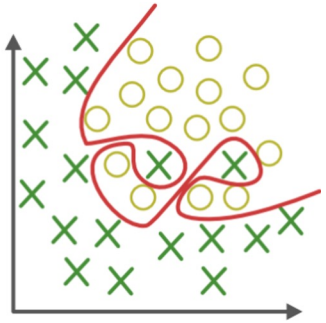
UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Train Test Split

Comprobar predicciones del modelo:

Opción A: Puesta de Producción. No recomendada

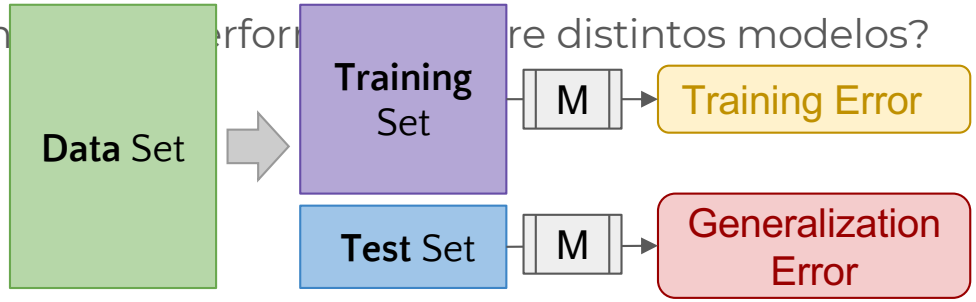
Opción B: Utilizando **Test Set**.



Training Error Bajo, Generalization Error Alto -> **Overfitting**

¿Cómo corregir y ajustar el modelo?

¿Cómo com erfor re distintos modelos?



UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

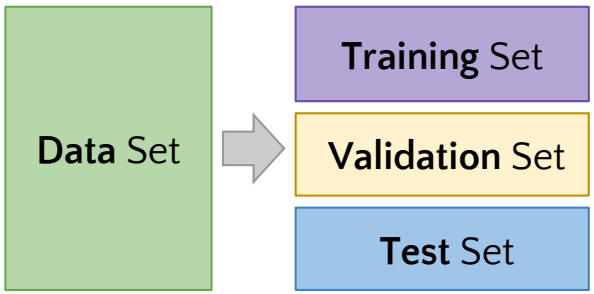
Testing and Validation

Opción C: Utilizando **Validation Set**.

Entrenar modelo mediante el **training set**.

Optimizar y seleccionar el modelo con mejor performance en el **validation set**.

Finalmente **chequear** resultados en el **Test set** *(Una vez que se está seguro que es el mejor modelo posible)* .



Test set 20%

Validation set 20%

Training set 60%.

UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

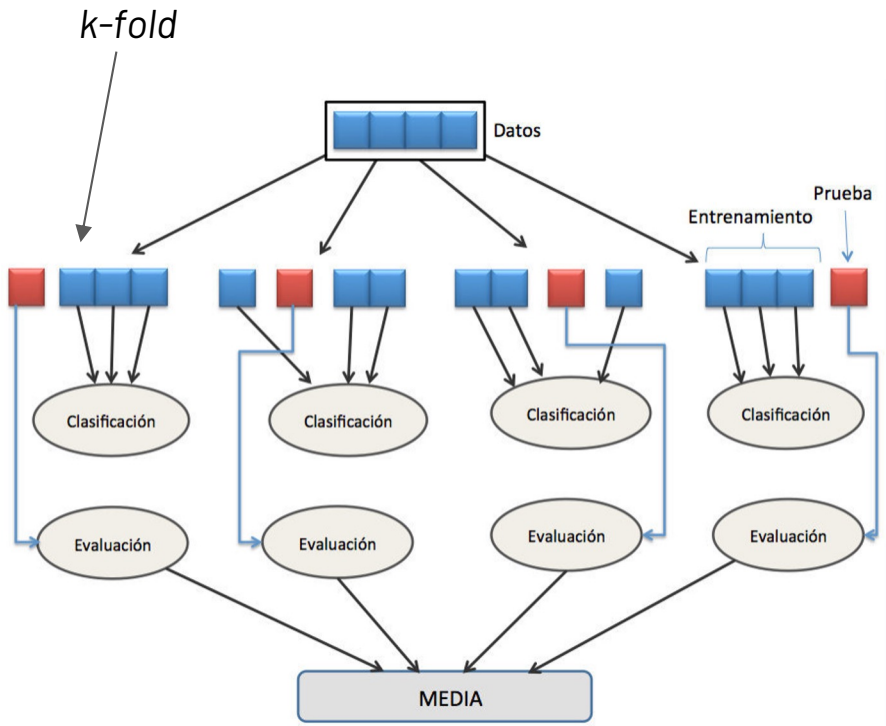
Test Set

- **Stratified sampling**:
  - Dataset se divide en grupos homogéneos (stratas).
  - Mutuamente excluyentes.
  - De cada Strata, se seleccionan cantidad representativa de observaciones
  - Aplicar Random sampling.



UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Cross Validation



1. División del training set en **k-folds.**

1. Cada modelo:
   - Entrenado con train folds.
   - Validado con fold restante.
   - K iteraciones.

✓ Modelo final y optimización, entrenado con training set completo.

✓ Error de generalización medido mediante el test set.

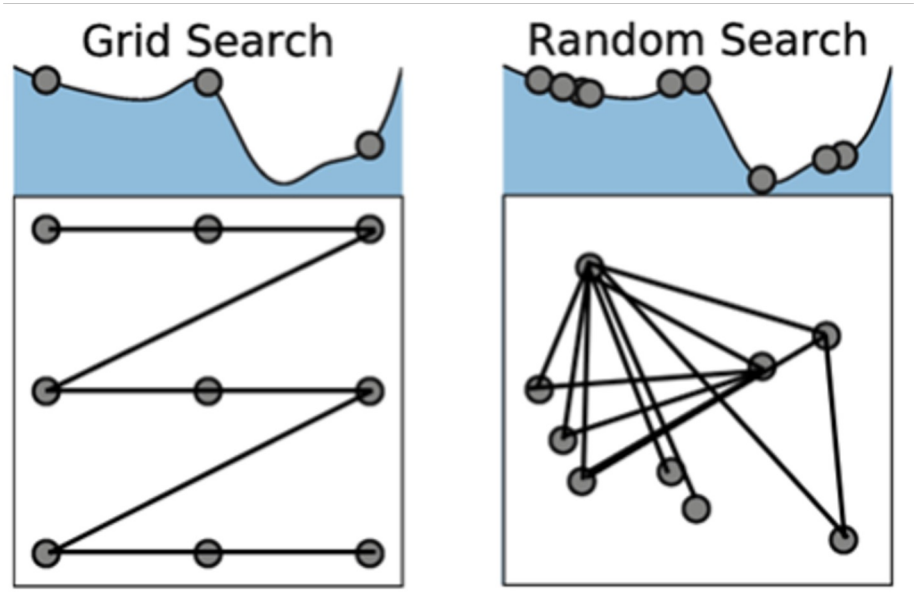
UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Optimización de hiperparámetros

Selección de hiperparámetros:

1. **Grid Search**
   Prueba combinaciones a partir de lista de valores posibles.

2. **Randomized Search**
   Prueba N combinaciones de valores al azar.



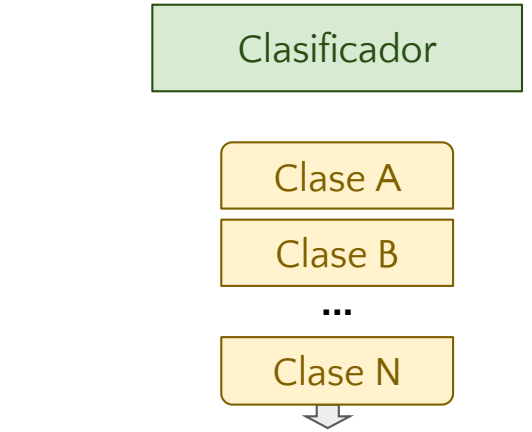
***Hiperparámetro**: valor configurado antes del entrenamiento de un modelo que influye en su performance.*

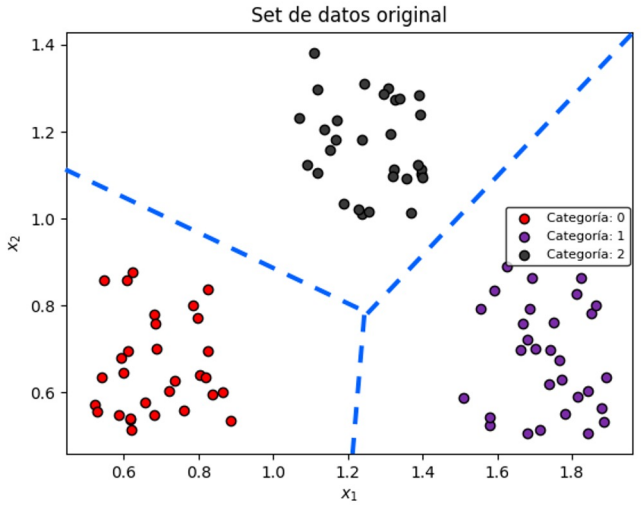
Clasificadores Multiclase

Estrategias Multiclase

Clasificar en más de 2 clases...

- Clasificación multiclase con clasificadores multiclases. (*Random forest)*
- Clasificación multiclase con clasificadores binarios (*SVM)*

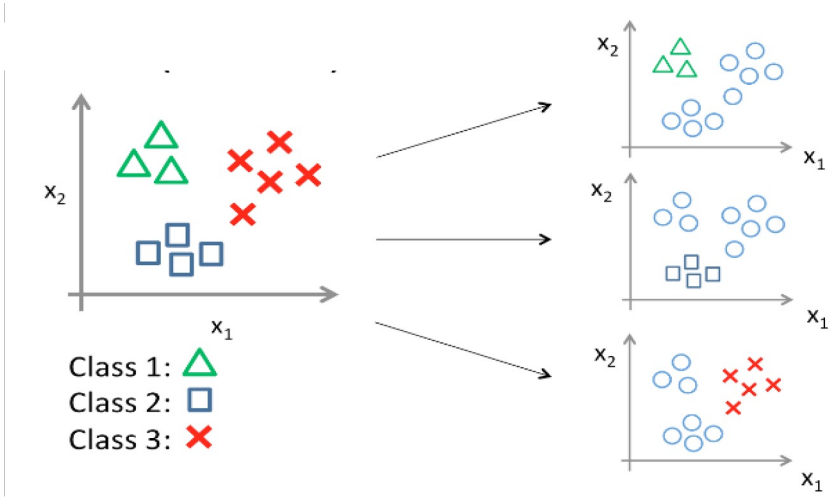




UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Estrategias Multiclase

OvA: One-versus-All



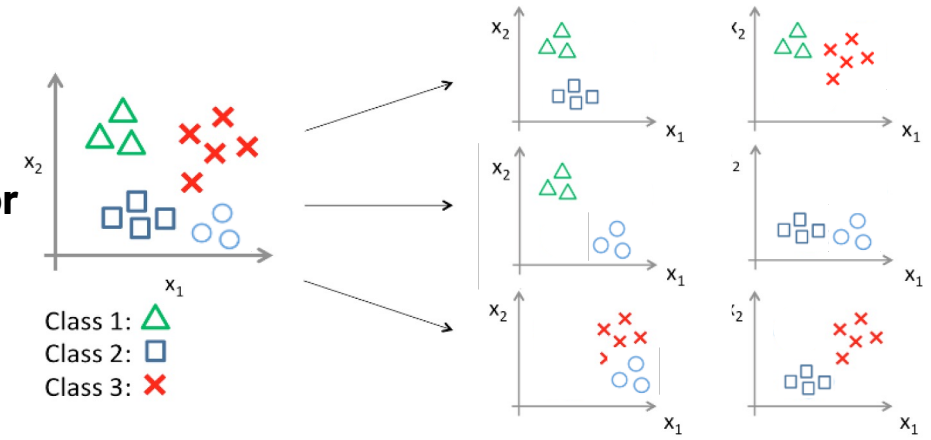
- Un clasificador **por clase**.
  - *Triangulos vs No Triangulos*
  - *Cuadrados vs No Cuadrados*
  - *Cruces vs No Cruces*
- *n* Clases, *n* Clasificadores.
- Predicción: Clase **mayor *score***.
  - Score para Triangulo del clasificador de triangulos.
  - Score para Cuadrados del clasificador de cuadrados
  - Score para Cruces del clasificador de cruces

UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Estrategias Multiclase

- Un clasificador **por par** de clases.
- *n* Clases, *n*(n-1)/2* Clasificadores.
- Predicción: Clase seleccionada **en mayor cantidad** de pares.
- *Ventaja*: cada uno se entrena en un subconjunto de 2 clases del training set.

  Desventaja: Coste computacional

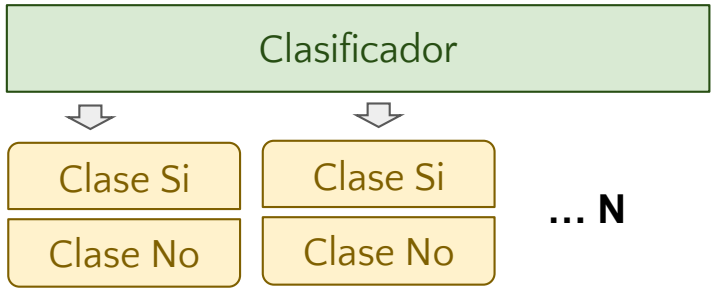


UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Multi Label Classifiers

Permiten que **cada instancia** (y predicción) tenga **mas un target** o label **binario**.

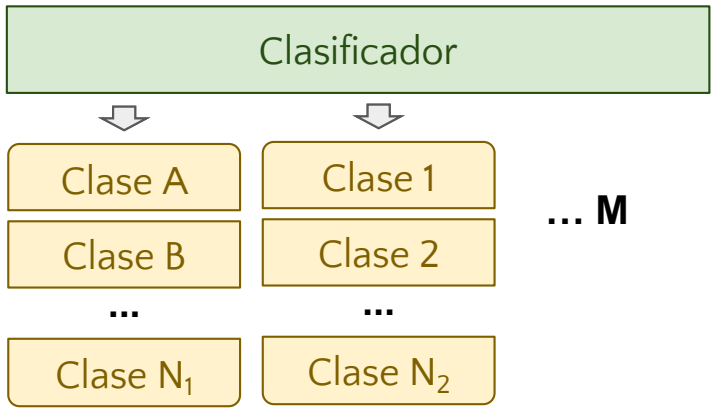
Ejemplo: Reconocer presencia de animales en una foto.



Generalización de los anteriores.

Clasificador:

- Múltiples targets o labels.
- Targets son multiclase.

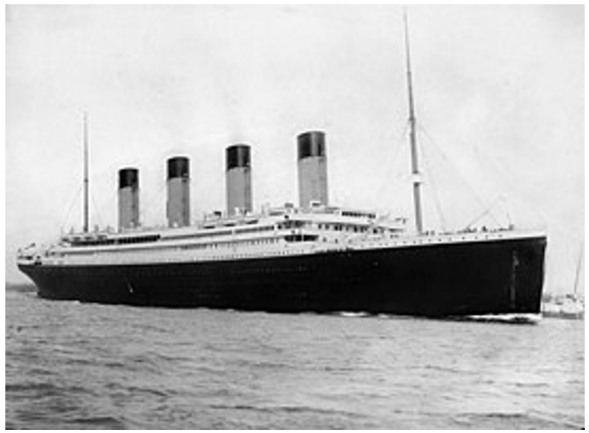


UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Predicción de sobrevivientes del titanic

Dataset de Titanic

- Predice la supervivencia de pasajeros en el Titanic basándose en características como la clase del pasajero, edad, sexo, etc.
- Aproximadamente 891 instancias y 12 características.
- Binario, con **dos clases** posibles: **sobrevivió** (**1**) o **no sobrevivió** (**0**)



UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Dataset de Titanic

	PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch
0	1	0	3	Braund, Mr. Owen Harris	male	22.0	1	0
1	2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.0	1	0
2	3	1	3	Heikkinen, Miss. Laina	female	26.0	0	0

Si entreno un árbol de decisión con esto para predecir si la gente sobrevive o no, cómo evalúo que tan bien predice el modelo?

UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Dataset de Titanic

	PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch
0	1	0	3	Braund, Mr. Owen Harris	male	22.0	1	0
1	2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.0	1	0
2	3	1	3	Heikkinen, Miss. Laina	female	26.0	0	0

Si entreno un árbol de decisión con esto para predecir si la gente sobrevive o no, cómo evalúo que tan bien predice el modelo?

Preprocesado y división de datos

Levantamos el dataset, limpiamos los datos y separamos en X e y:

```
import pandas as pd
from sklearn.model_selection import train_test_split

# Cargar dataset
data = pd.read_csv('titanic.csv')
data = data[['Age', 'Fare', 'Pclass','Sex','Survived']].dropna()

# Codificar variable categórica 'Sex'
data['Sex'] = data['Sex'].map({'male': 0, 'female': 1})

# Definir X y y
X = data[['Age', 'Fare', 'Pclass', 'Sex']]
y = data['Survived']

# Dividir en train y test
X_train, X_test, y_train, y_test = train_test_split(X, y,
test_size=0.2, random_state=42)
```

UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Entrenamiento y evaluación del modelo

Entrenamos nuestro modelo para predecir si sobrevive al accidente del Titanic:

```
from sklearn.linear_model import DecisionTreeClassifier
from sklearn.metrics import accuracy_score

# Crear y entrenar el modelo
model = DecisionTreeClassifier(max_depth=3) # Jugar con altura
máxima del arbol
model.fit(X_train, y_train)

# Realizar predicciones
y_pred = model.predict(X_test)

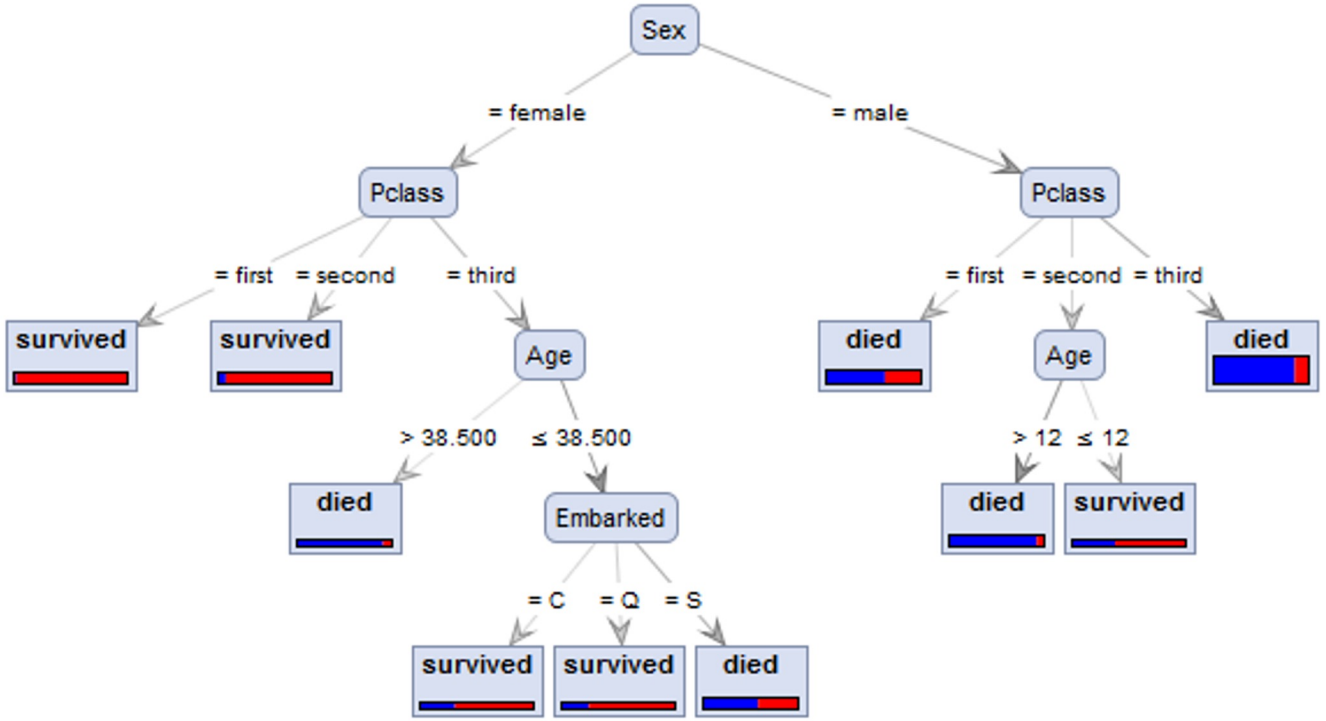
# Evaluar el rendimiento del modelo
accuracy = accuracy_score(y_test, y_pred)
print("Accuracy:", accuracy)
```

```
Accuracy: 0.8212290502793296
```

UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Visualización del árbol

Podemos visualizar cómo clasifica nuestro arbol los datos a partir de sus atributos



UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES