Introducción a Ciencia de Datos

Evaluación de modelos de clasificación y regresión

UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Métricas de Performance para clasificación

Accuracy

- **Proporción de predicciones correctas** sobre el total de predicciones.



$$A_{(modelo)} = \frac{\text{Predicciones Correctas}}{\text{Cantidad de predicciones}}$$

Métrica muy sencilla pero con muchos problemas, ideal para arrancar

Accuracy Paradox



Solo 10% de las imágenes son 5s.

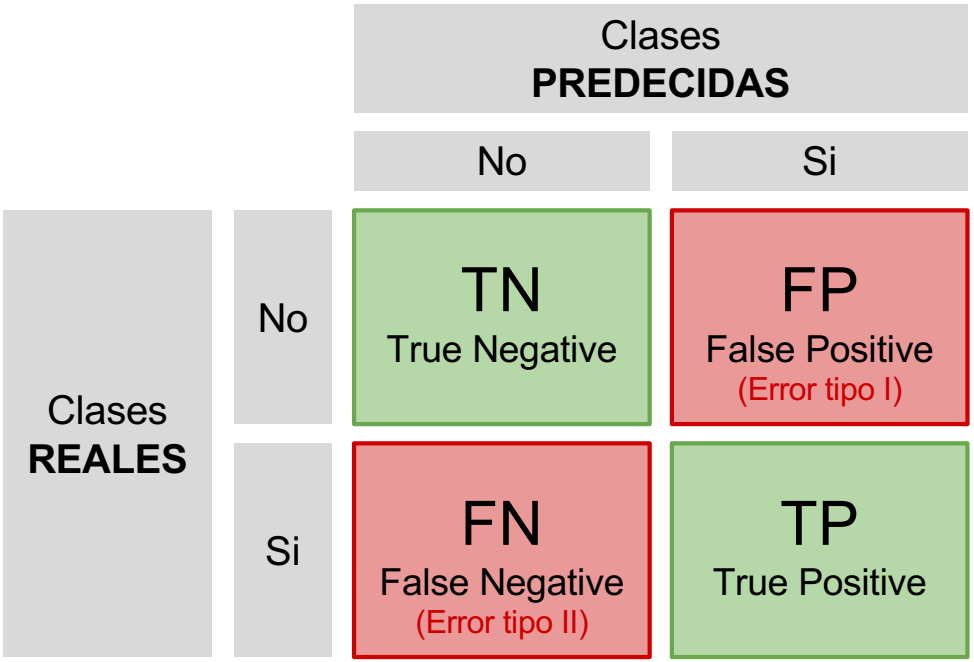
Modelo: $\forall i$ P(i) -> Falso, implica 90% de exactitud.

Accuracy Paradox:

- Modelos con un nivel dado de *accuracy* pueden tener mejor poder de predicción qué modelo con mayor *accuracy*.
- Modelos pueden tener buena *accuracy* pero ser inútiles.
- Sobre todo cuando existen clases más frecuentes que otras.

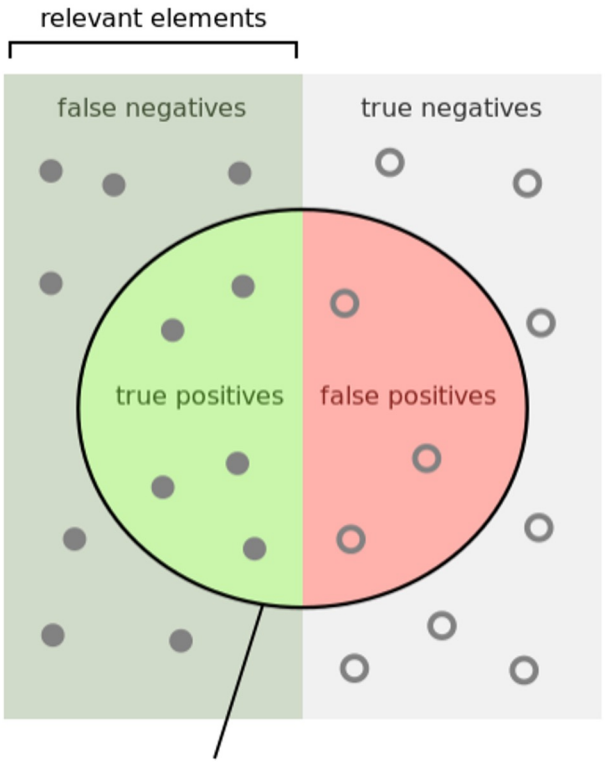
UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Confusion Matrix



UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Confusion Matrix Gráficamente



Instancias clasificadas como naranja por el modelo

Clasificador de naranjas

Instancias:

- Naranjas
- Manzanas

Ejemplo: Accuracy Paradox

Clasificador A

Clases **REALES**			Clases **PREDECIDAS** No	Clases **PREDECIDAS** Si
9850 Instancias **NO**		No	9,700 True Negative	150 False Positive
150 Instancias **SI**		Si	50 False Negative	100 True Positive

Clasificador Fijo

	Clases **PREDECIDAS** No	Clases **PREDECIDAS** Si
No	9,850 True Negative	0 False Positive
Si	150 False Negative	0 True Positive

UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Ejemplo: Accuracy Paradox

$$A_{(modelo)} = \frac{\text{Correctas}}{\text{Total}} = \frac{TN + TP}{TN + TP + FN + FP}$$



$$A_{(clasificadorA)} = \frac{9\,700 + 100}{9\,700 + 100 + 50 + 150} = 98\ \%$$

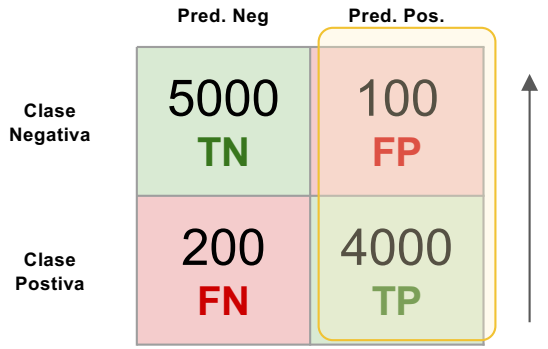
$$A_{(clasificadorFijo)} = \frac{9\,850 + 0}{9\,850 + 0 + 0 + 150} = 98.5\ \%$$

UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Precision & Recall

Precision: Exactitud de las predicciones positivas.

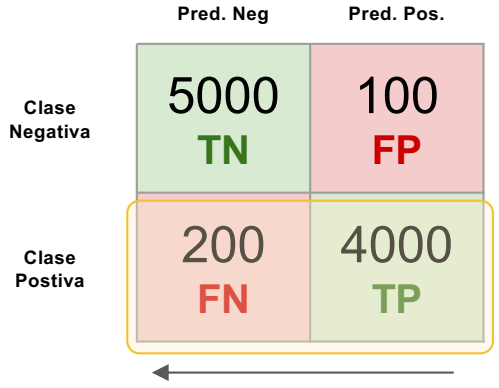
$$P_{(modelo)} = \frac{TP}{TP + \mathbf{FP}}$$



Precision = *4000 / 4100 = 0.97*

Recall: Exactitud de las predicciones, sobre solo las instancias reales positivos:

$$R_{(modelo)} = \frac{TP}{TP + \mathbf{FN}}$$



Recall = *4000 / 4200 = 0.95*

UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

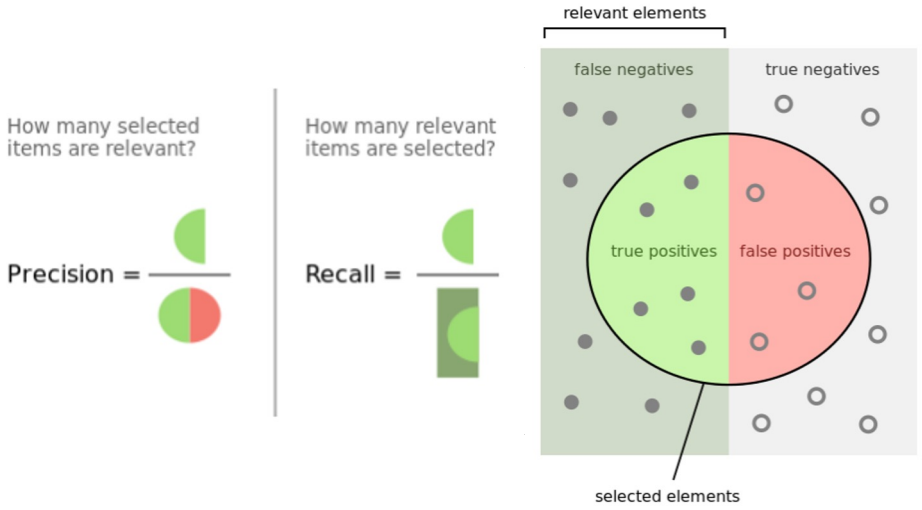
Precision & Recall Gráficamente

Precision: Exactitud de las predicciones positivas.

$$P_{(modelo)} = \frac{TP}{TP + \mathbf{FP}}$$

Recall: Exactitud de las predicciones, sobre solo las instancias reales positivos:

$$R_{(modelo)} = \frac{TP}{TP + \mathbf{FN}}$$



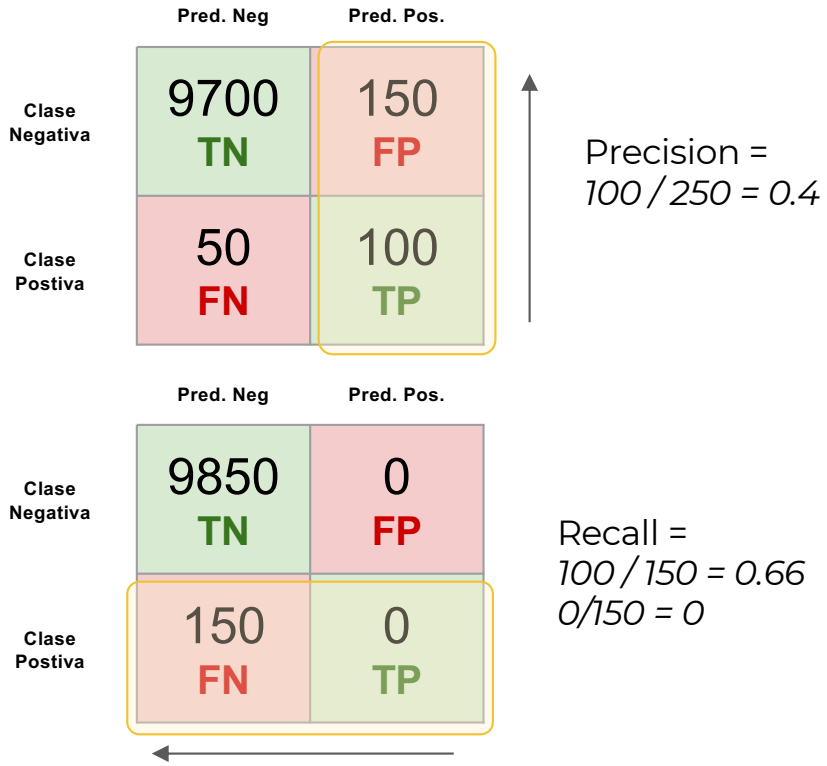
Precision & Recall

Precision: Exactitud de las predicciones positivas.

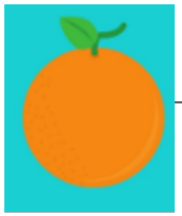
$$P_{(modelo)} = \frac{TP}{TP + \mathbf{FP}}$$

Recall: Exactitud de las predicciones, sobre solo las instancias reales positivos:

$$R_{(modelo)} = \frac{TP}{TP + \mathbf{FN}}$$



Decision Threshold



Clasificador

score = Clasificador(*instance*)

Score P

Umbral T

Score > Umbral T?

Naranja

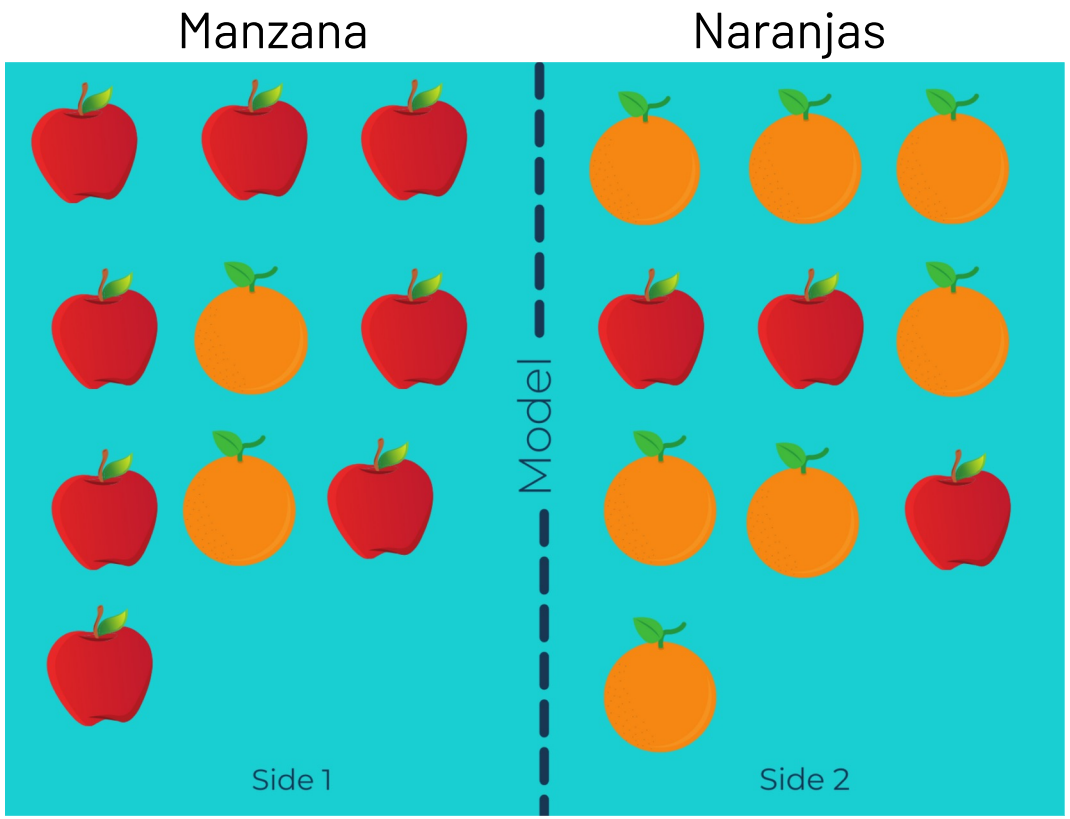
Manzana

Tenemos un clasificador de naranjas y manzanas.

El clasificador además nos dice la "**probabilidad"** de que sea una naranja o no.

Después vemos cómo se calcula...

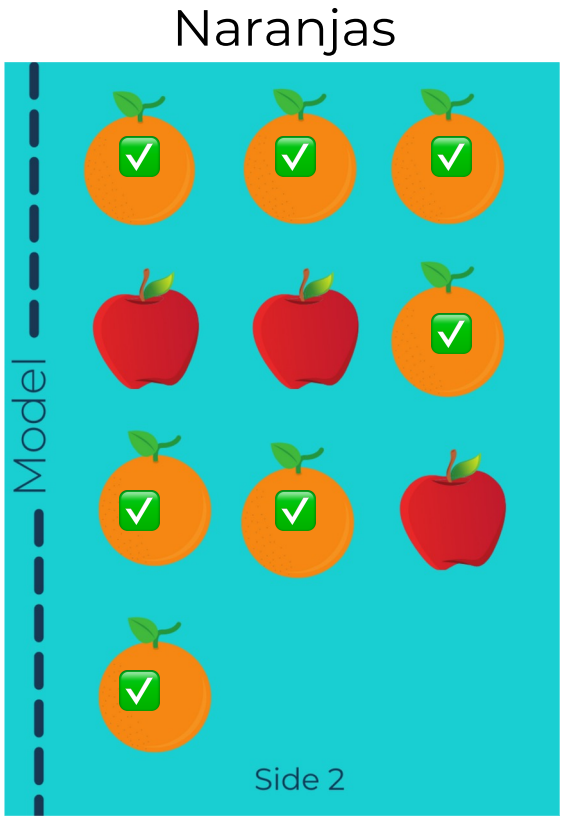
Precision vs Recall



Precisión

P = 7/10

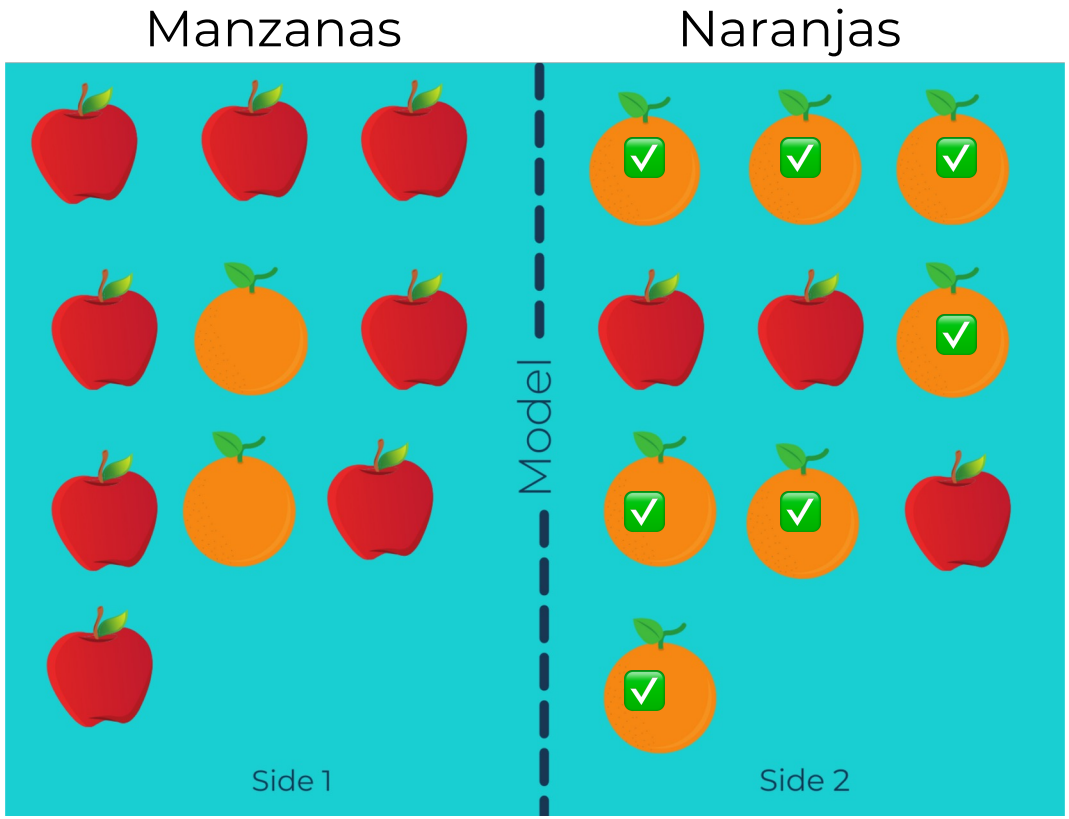
$$\frac{\text{Total naranjas correctas}}{\text{Total naranjas predichas}}$$



Recall

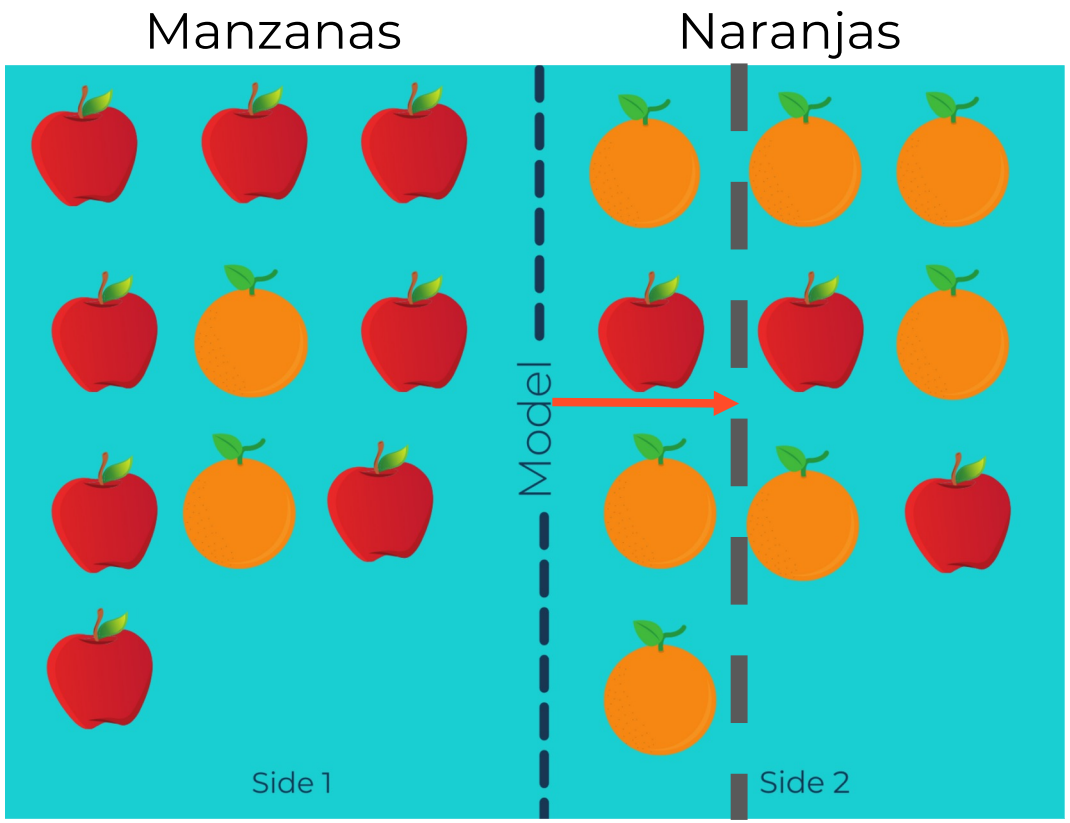
R = 7/9

$$\frac{\text{Total naranjas correctas}}{\text{Total de naranjas}}$$



UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Decision Threshold



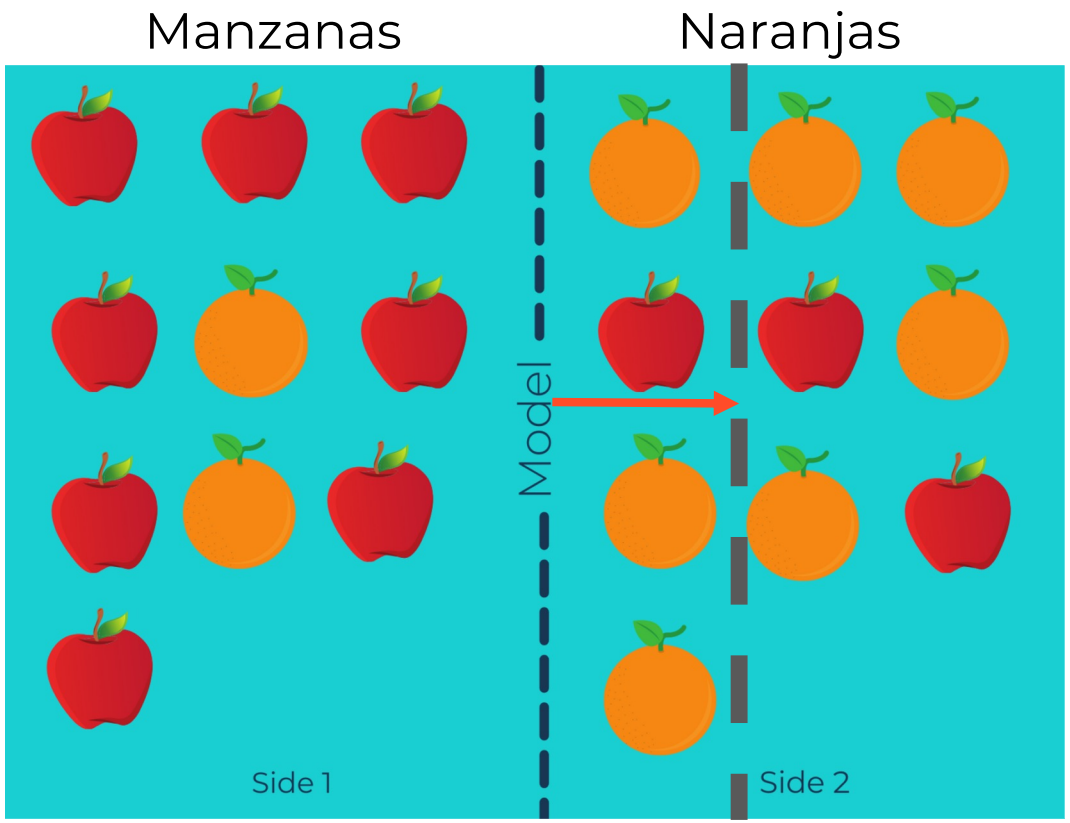
Movemos el threshold del modelo.

Nuevos valores:

P =

R =

Decision Threshold



Movemos el threshold del modelo.

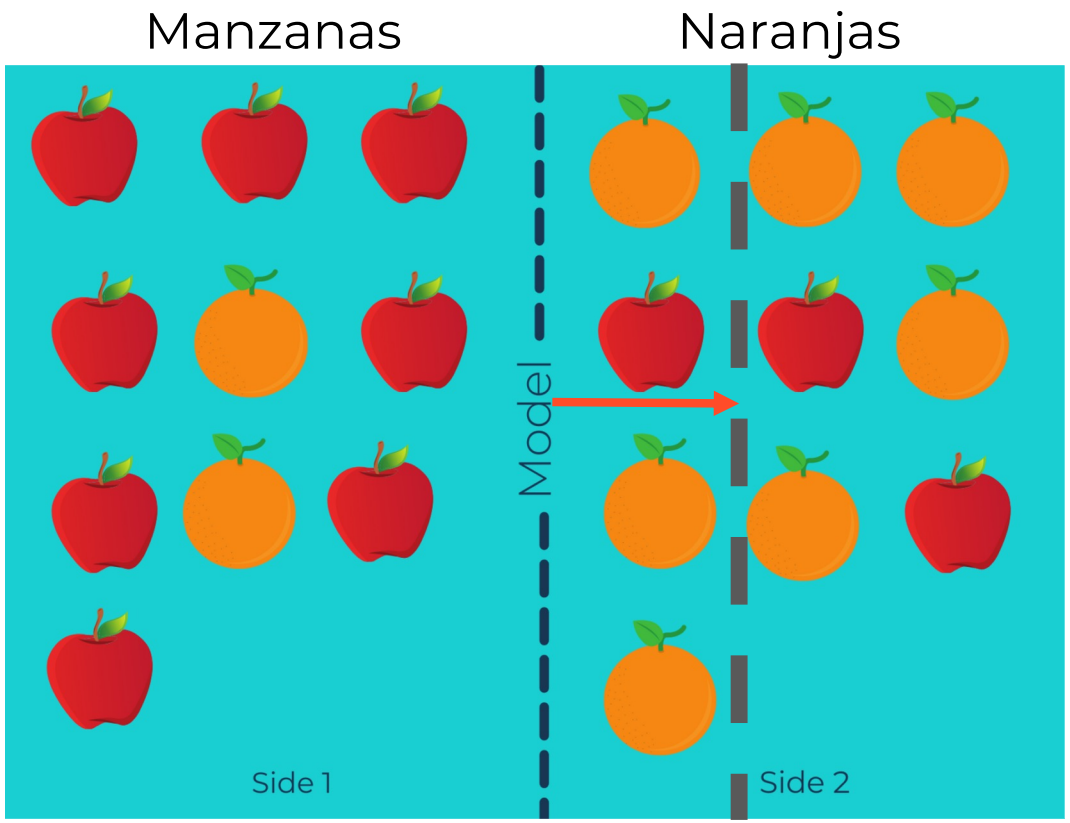
Nuevos valores:

P = 4/6

R = 4/9

UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Decision Threshold



Movemos el threshold del modelo.

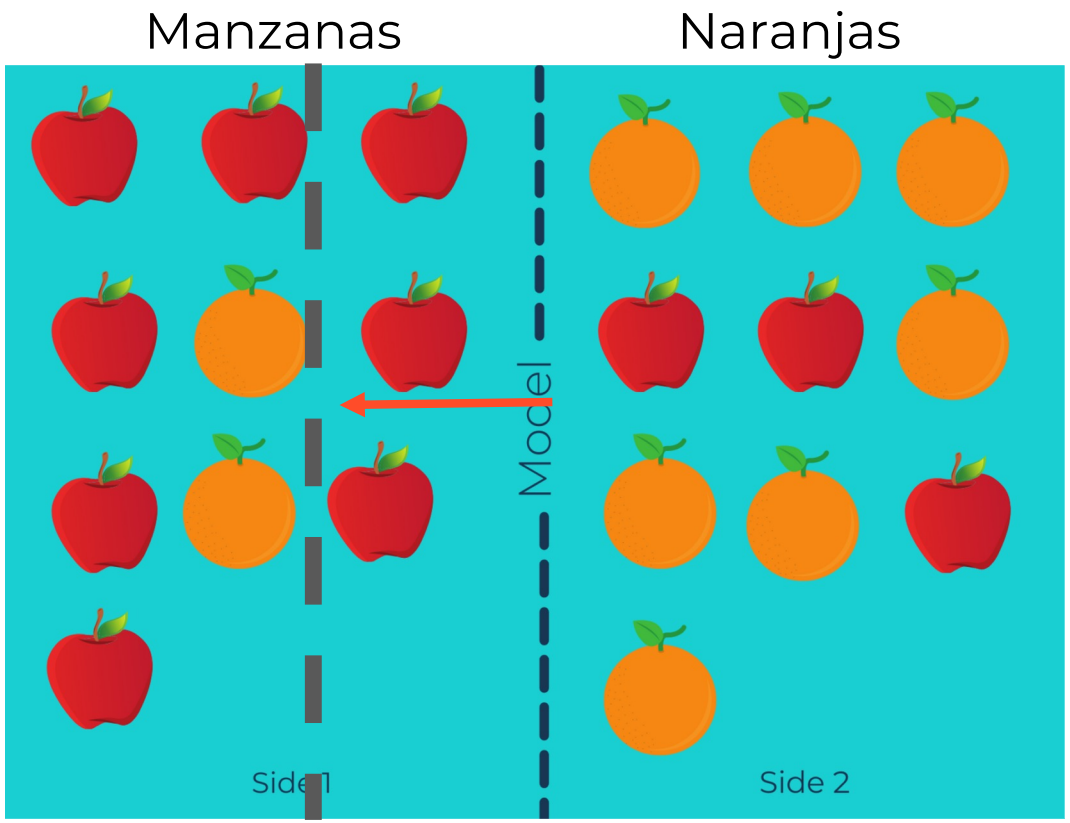
Nuevos valores:

P = 4/6 ↓

R = 4/9 ↓

UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Decision Threshold



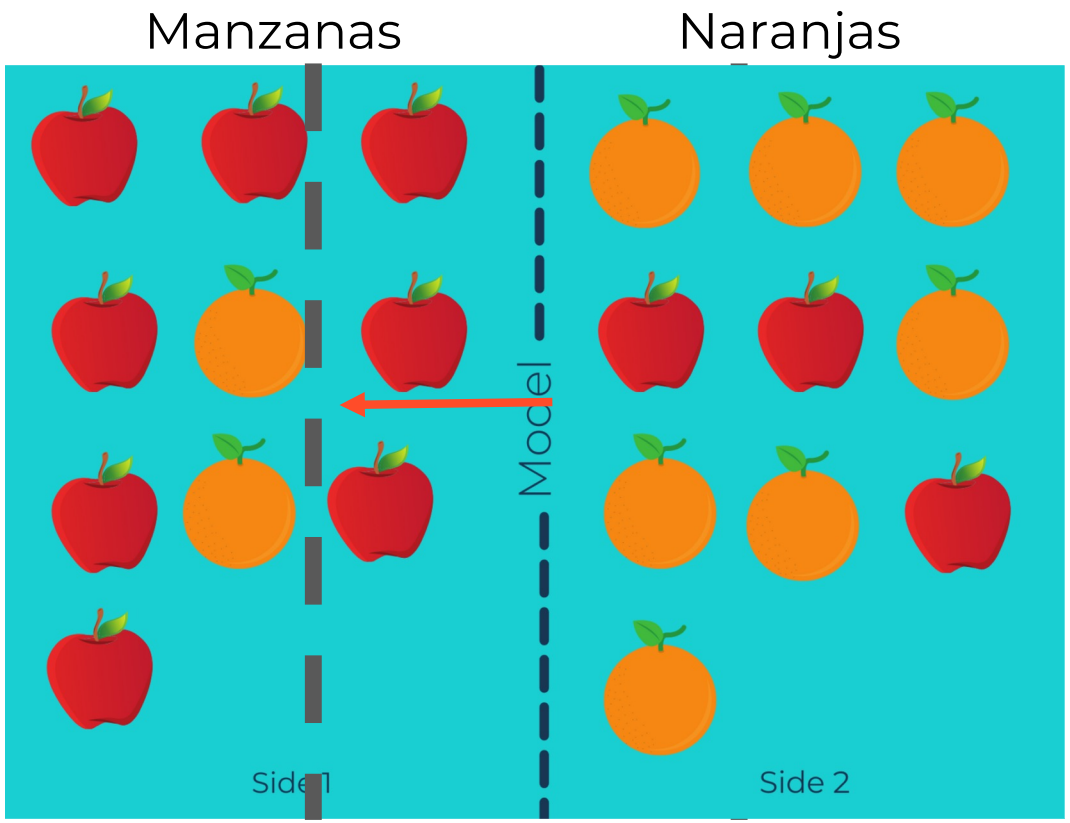
Movemos el threshold del modelo.

Nuevos valores:

P =

R =

Decision Threshold



Movemos el threshold del modelo.

Nuevos valores:

P = 7/13 ↓

R = 7/9 =

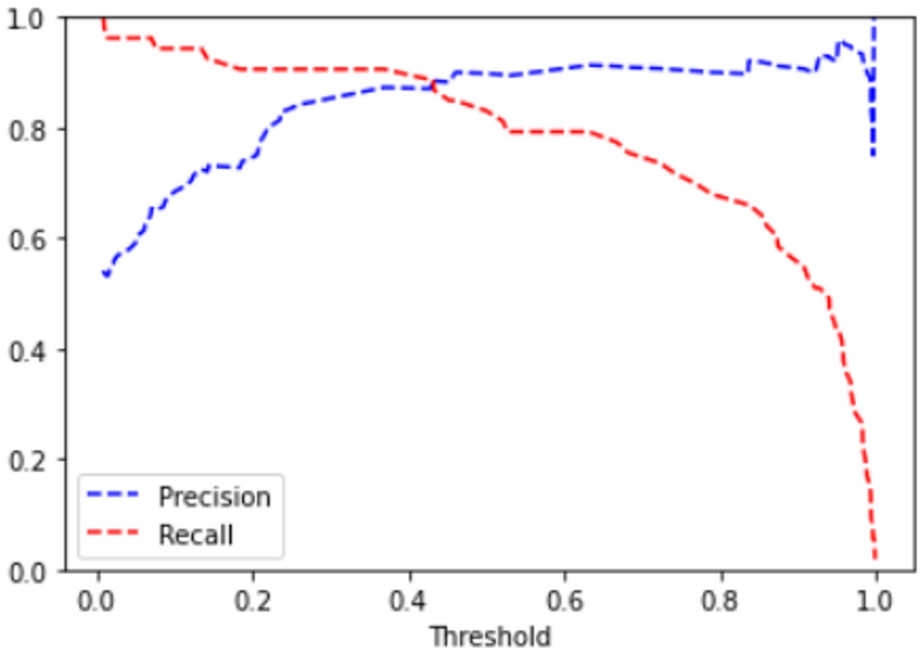
UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Selección del Threshold

Seleccionar el mejor Threshold para cada situación.

- Clasificar publicidad ATP?
  Evitar predecir cómo mainstream, publicidades no-mainstream.

- Detectar fraude en tarjetas de crédito?
  Detectar cualquier transacción con posibilidad de fraude.



UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

F1 Score : Precision + Recall

Combinar **Precisión** y **Recall** en una sola métrica.

$$F_{1(modelo)} = \frac{2}{1/P_{(modelo)} + 1/R_{(modelo)}} = 2 \times \frac{P_{(modelo)} \times R_{(modelo)}}{P_{(modelo)} + R_{(modelo)}}$$

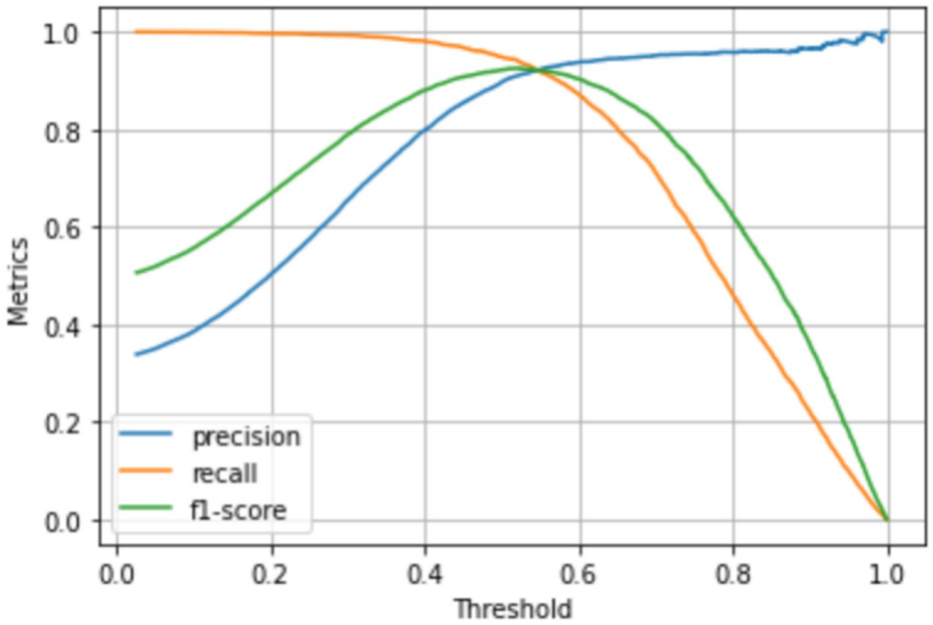
- Media armónica: poco influenciada por la existencia de valores mucho más grandes que el conjunto de los otros (Sensible a valores chicos).
- Favorece clasificadores con similar y altos *precision* y *recall*.

Selección del Threshold

Seleccionar el mejor Threshold para cada situación.

- Clasificar publicidad ATP?
  Evitar predecir cómo mainstream, publicidades no-mainstream.

- Detectar fraude en tarjetas de crédito?
  Detectar cualquier transacción con posibilidad de fraude.



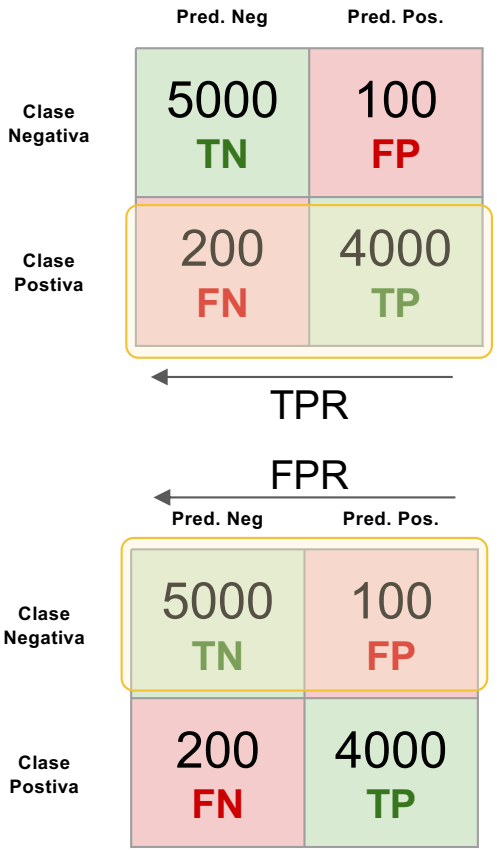
Espacio ROC

El nombre viene de **Receiver operating characteristic** y se utiliza mucho en detección de señales.

Se construye comparando True Positive Rate vs False Positive Rate.

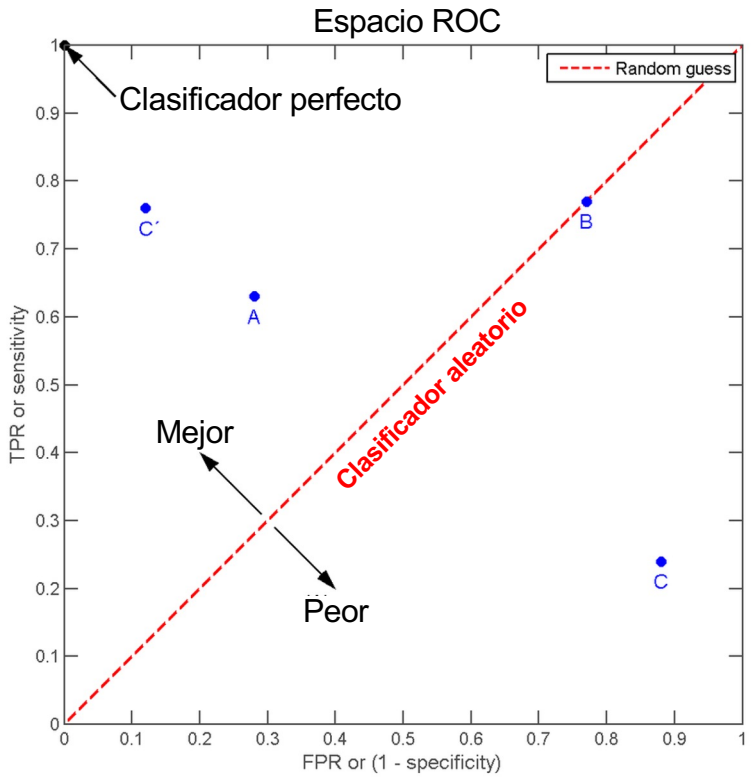
- **TRUE Positive Rate**: *TP / (TP + FN)*: De las instancias de clase positiva, cuántas predicen como positivas (=Sensitivity/Recall).

- **FALSE Positive Rate:** *FP / (FP + TN)*: De las instancias de clase negativa, cuántas predicen como positivas.



Espacio ROC

- Clasificación perfecta en (0,1)
- Línea de no-discriminación
- Ej. de 3 Modelos de clasificación: A, B, C.



UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

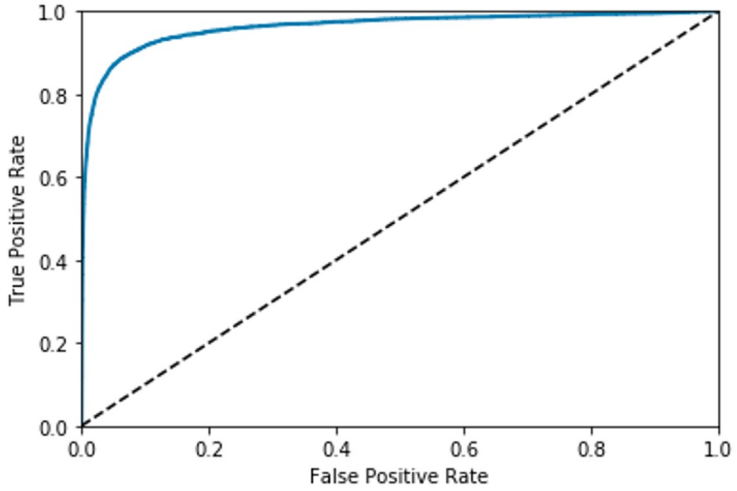
Curva ROC

Se obtiene variando el Threshold.

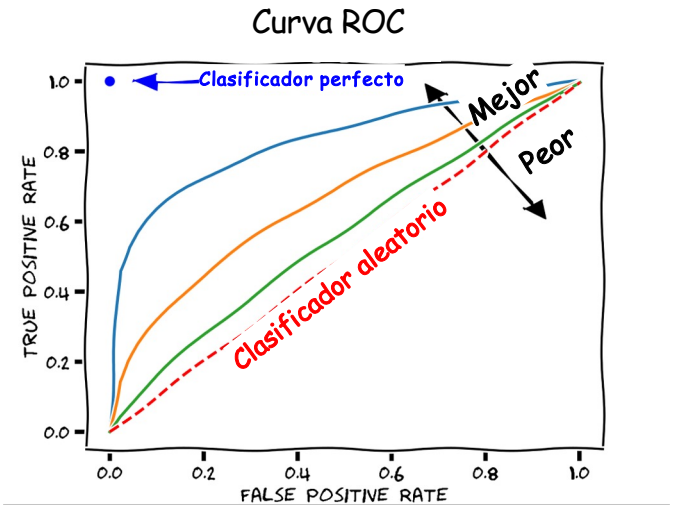
1. Computar curva ROC.
2. Graficar.

Tradeoff (nuevamente): TP rate vs FP rate.

Qué métrica le calculamos a la curva ROC?



AUC: Area bajo la curva



- Representación gráfica que **muestra el rendimiento** de un modelo de **clasificación binaria**
- Proporciona un valor entre **0.5 y 1** que indica **qué tan bien separa** el modelo las **clases**. Un AUC **cercano a 1** indica un modelo con **buen desempeño**.

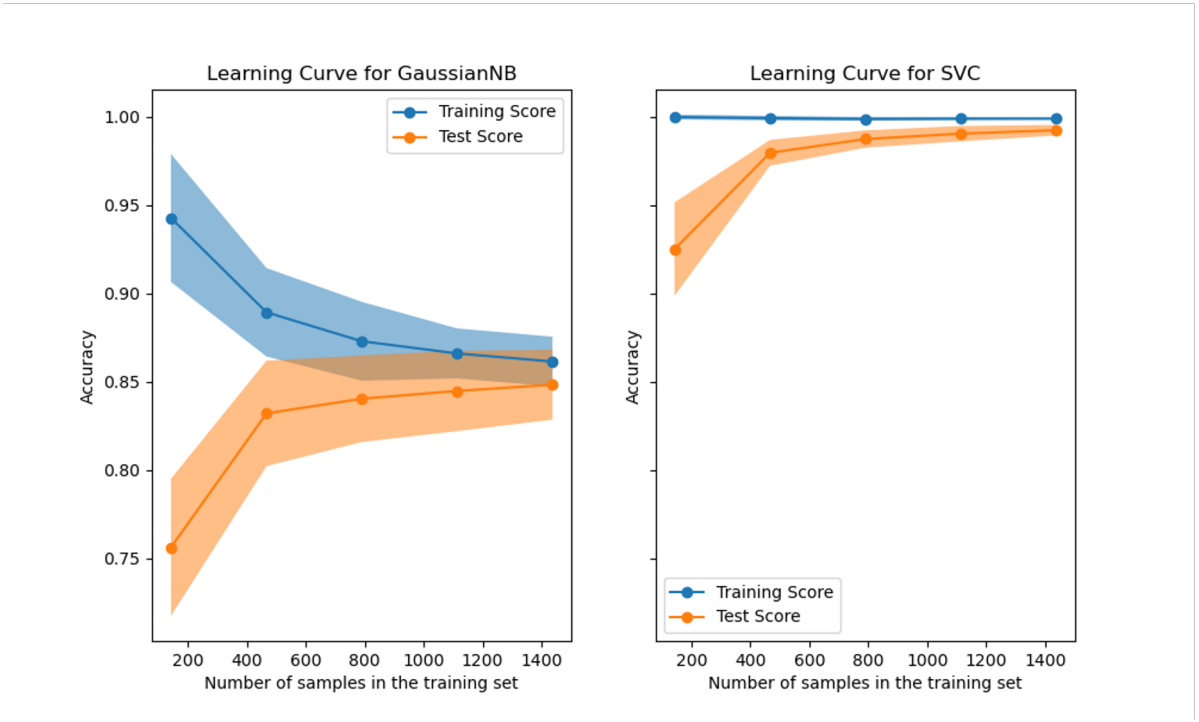
Comparar clasificadores: 1 > AUC > 0.5

UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Curva de aprendizaje

Curva que relaciona tamaño del Dataset de entrenamiento con el accuracy u otra métrica en el mismo set de entrenamiento y un set de validación **(siempre es el mismo a pesar de que cambie el set de entrenamiento)**.

La idea es determinar si tenemos **beneficio** en agregar más datos.

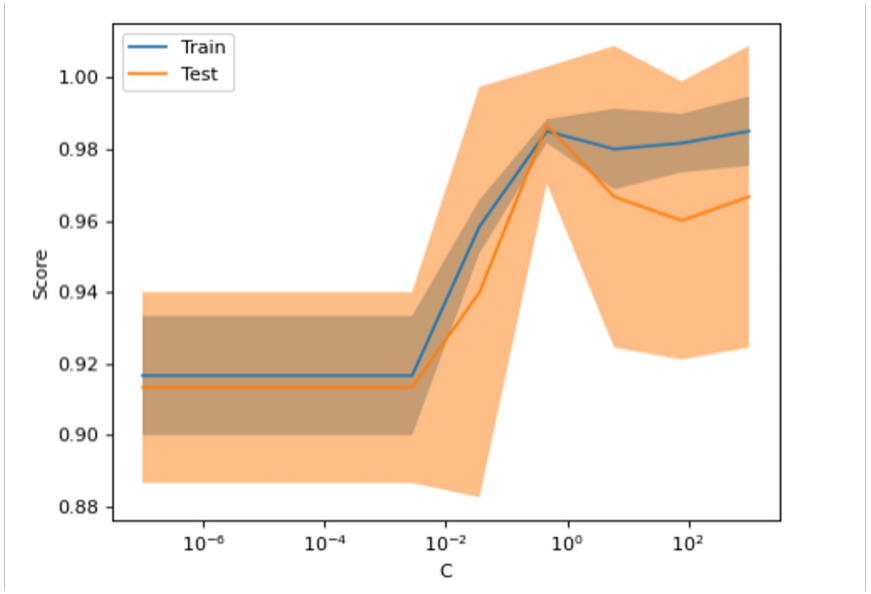


UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Curva de validación/complejidad

Curva que relaciona el valor de **un hiperparámetro** con el accuracy u otra métrica en el mismo set de entrenamiento y un set de validación.

La idea es determinar es en qué regiones tenemos **overfitting** y **underfitting** para ese hiperparámetro.

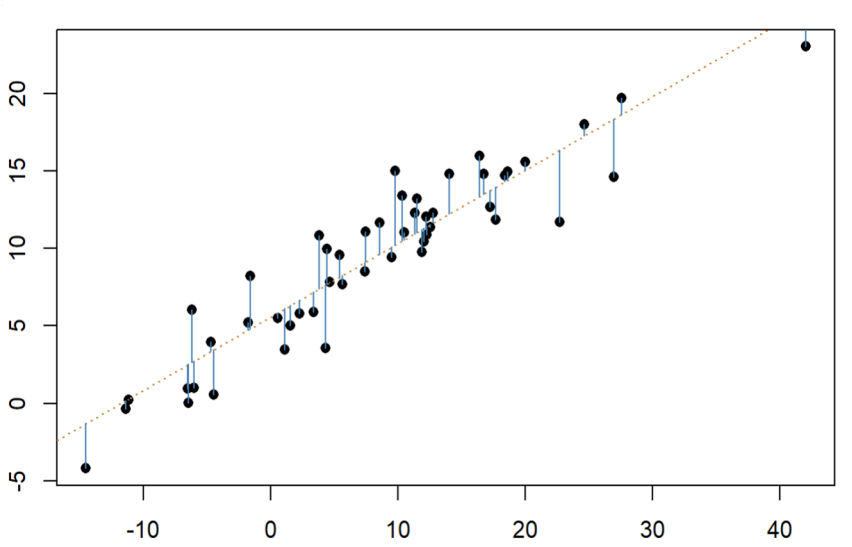


UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Modelo de Regresión: Clasificador lineal

Breve repaso: Regresión

- Tipo de modelo predictivo utilizado para predecir un valor numérico continuo basado en una o más variables independientes.
- Encuentra la relación entre las **variables independientes** (predictoras) y la **variable dependiente** (respuesta) para hacer predicciones.
- **Aplicaciones:** Predicción de precios, estimación de riesgos, análisis de tendencias, etc.



UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Modelos de regresión

Y Variable independiente

$X = (X_1, X_2, \ldots, X_n)$ Variables dependientes (Vector N dimensiones)

$$Y = f(X) + \epsilon$$

Puedo modelar la variable Y mediante la función f(X) más un término de error.

- Precio de venta del producto
- Inversión en publicidad
- Precio de venta de la competencia
- Unidades vendidas por la competencia

¿Conviene subir el precio para vender más?
¿Estamos gastando poco o mucho en publicidad?
¿Qué pasa si a nuestros competidores les va mejor o peor?

Regresión Lineal

Y Variable independiente

$X = (X_1, X_2, \ldots, X_n)$ Variables dependientes (Vector N dimensiones)

$$Y = f(X) + \epsilon$$

Regresión lineal: La f(X) es una función lineal (N+1 parámetros)

$$f(X) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \ldots + \beta_n X_n$$

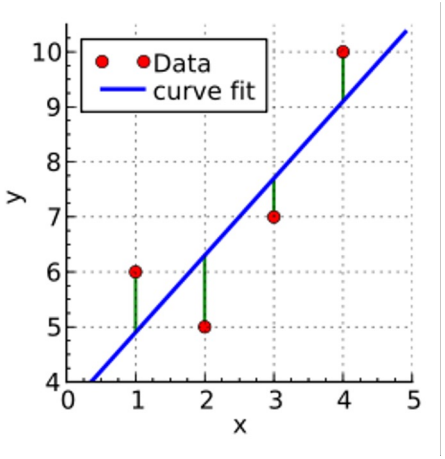
Regresión Lineal

$$Y = f(X) + \epsilon$$

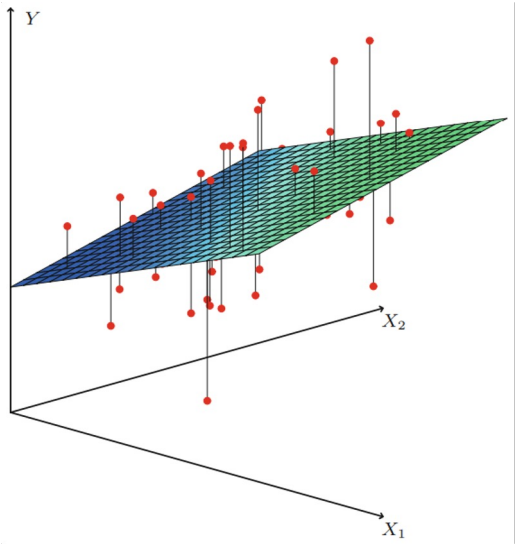
Regresión lineal: La f(X) es una función lineal (N+1 parámetros)

$$f(X) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \ldots + \beta_n X_n$$

n = 1



n = 2



UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

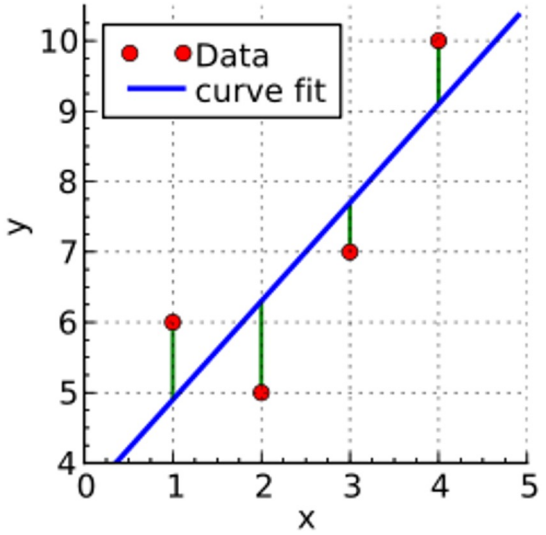
Medida de performance - RMSE

$$\sqrt{\sum \frac{(y_{pred} - y_{ref})^2}{N}}$$

Root Mean Square Error

Mide la desviación estándar del error de las predicciones que hace el sistema.

Muy utilizado en problemas de regresión.



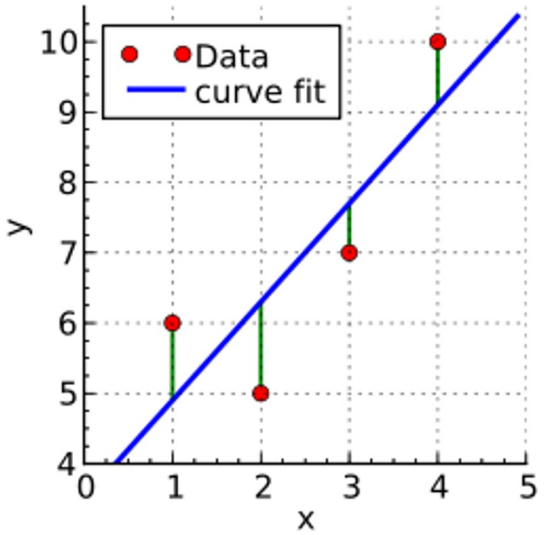
UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Medida de performance - RMSE

Existen varias medidas de performance. Dependiendo las situaciones algunas son mejores que otras.

$$\mathrm{RMSE}(\mathbf{X}, h) = \sqrt{\frac{1}{m}\sum_{i=1}^{m}\left(h\left(\mathbf{x}^{(i)}\right) - y^{(i)}\right)^2}$$

- **x(i)**: Vector con los valores de la medición *i* para cada una de las *features*.
- **y(i)**: *Label*, valor real (y predicción deseada) para la medición *i*.
- **h(x(i))**: Predictor del valor y(i).
- ***m***: Cantidad de mediciones.

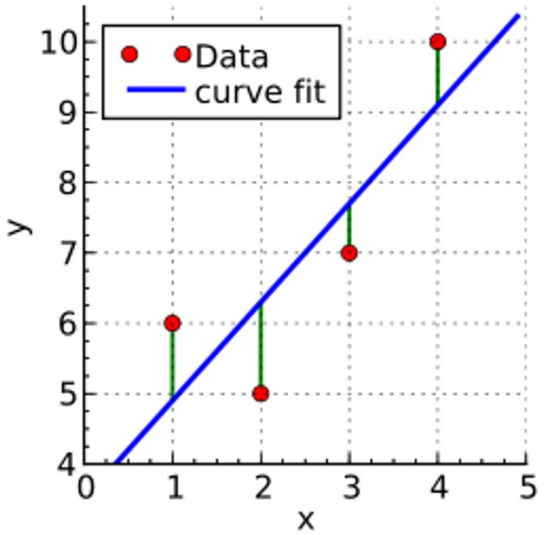


UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Medida de performance - RMSE

$$\mathrm{RMSE}(\mathbf{X}, h) = \sqrt{\frac{1}{m}\sum_{i=1}^{m}\left(h\left(\mathbf{x}^{(i)}\right) - y^{(i)}\right)^2}$$

- **x(i)**: Vector con los valores de la medición *i* para cada una de las *features*.
- **y(i)**: *Label*, valor real (y predicción deseada) para la medición *i*.
- **h(x(i))**: Predictor del valor y(i).
- ***m***: Cantidad de mediciones.



UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES

Medida de performance - MAE

Existen varias medidas de performance. Dependiendo las situaciones algunas son mejores que otras.

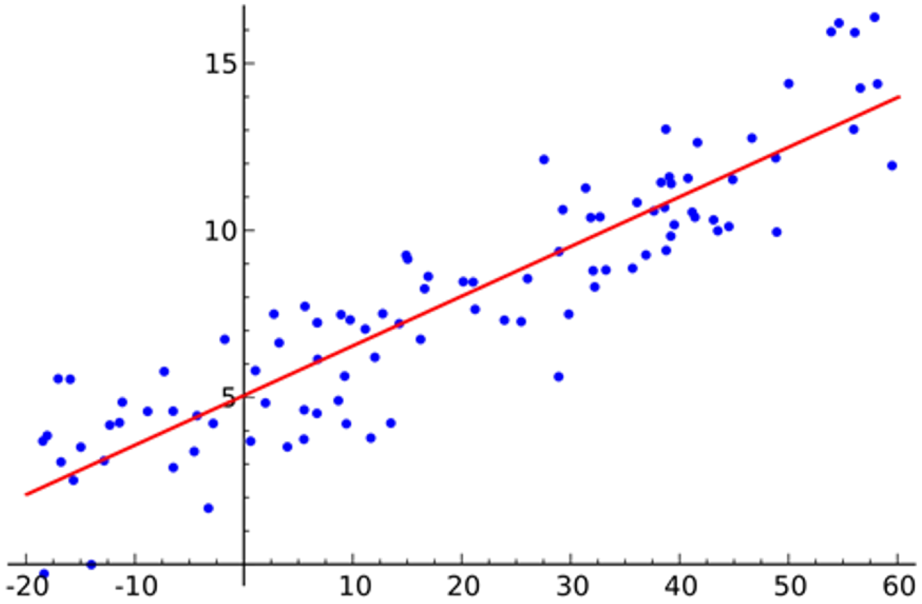
Mean Absolute Error (MAE)

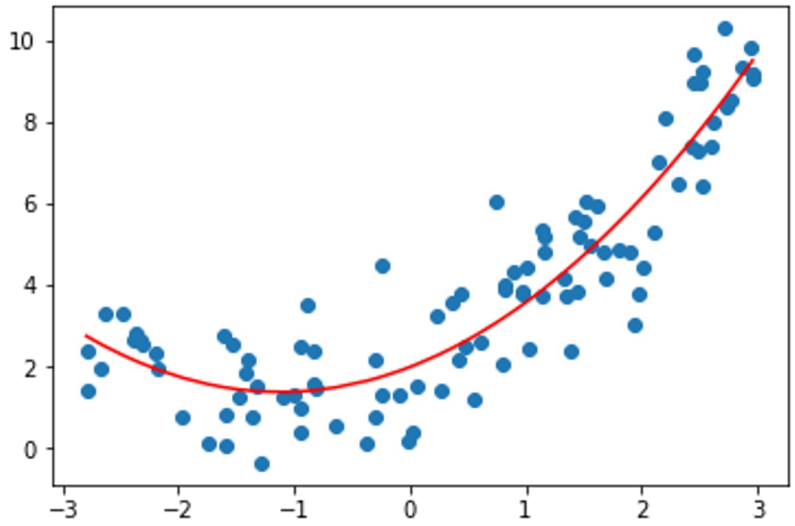
$$\mathrm{MAE}(\mathbf{X}, h) = \frac{1}{m}\sum_{i=1}^{m}\left|h\left(\mathbf{x}^{(i)}\right) - y^{(i)}\right|$$

- **x(i)**: Vector con los valores de la medición *i* para cada una de las *features*.
- **y(i)**: *Label*, valor real (y predicción deseada) para la medición *i*.
- **h(x(i))**: Predictor del valor y(i).
- ***m***: Cantidad de mediciones.

- Ambas, RMSE y MAE miden la distancia entre dos vectores, el de las mediciones y el de las predicciones.
- Menos susceptible a outliers (valores extremos).

Regresión lineal / polinomial





Aumenta la complejidad del modelo (Puede causar Overfitting).

Permite capturar relaciones más complejas (Evita Underfitting)

UTN.BA
UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL BUENOS AIRES