Contexto

Una organización dedicada al análisis de tendencias tecnológicas quiere entender **cómo percibe el público hispanohablante la inteligencia artificial** en redes sociales.

Para ello cuentan con un dataset de tweets en español relacionados con inteligencia artificial, que incluye tanto el **texto de los tweets** como **metadatos del usuario y métricas de interacción**.

El objetivo es construir un modelo que pueda **predecir el sentimiento de un tweet** (positivo, negativo o neutral) a partir de su contenido y de la información disponible. Esto les permitirá recolectar más datos a futuro y etiquetarlos automáticamente.

Desafío

El desafío consiste en desarrollar un **pipeline completo de Machine Learning** que permita predecir el sentimiento de un tweet.

Esto implica realizar todas las etapas típicas de un proyecto de ciencia de datos:

- Exploración del dataset
- Análisis de las variables disponibles
- Preprocesamiento del texto
- Ingeniería de features
- Entrenamiento de modelos
- Evaluación de resultados

El objetivo no es únicamente entrenar un modelo, sino **analizar las decisiones tomadas en cada etapa del proceso**.

Lineamientos

Durante el desarrollo del trabajo deberán investigar y justificar decisiones en distintas partes del pipeline. Algunas preguntas que pueden servir como punto de partida:

Exploración del dataset

Analicen la columna **polarity**.

- ¿Cuántos tweets hay por clase?
- ¿El dataset está balanceado?
- ¿Cómo puede afectar esto al entrenamiento de modelos?

Realicen un análisis exploratorio inicial del dataset:

- ¿Cuántos tweets contiene?
- ¿Qué columnas están disponibles?
- ¿Qué tipos de datos tiene cada variable?
- ¿Existen valores faltantes?

Análisis de las variables disponibles

El dataset incluye métricas de interacción como favorite_count o retweet_count. Exploren estas variables:

- ¿Qué distribución tienen?
- ¿Los tweets positivos reciben más interacción que los negativos?
- ¿Se observan outliers?

Ingeniería de features

Además de las variables existentes, pueden generar **nuevas features** que ayuden al modelo. Por ejemplo:

- Longitud del tweet.
- Cantidad de hashtags.
- Cantidad de usuarios mencionados.

Justifiquen por qué creen que estas variables podrían ser útiles.

Preprocesamiento de texto

Antes de aplicar técnicas de NLP como **Bag of Words** o **TF-IDF**, analicen cómo tratar distintos elementos del texto:

- URLs
- Hashtags

- Menciones a otros usuarios (@usuario)
- Emojis

Reflexionen sobre si deberían eliminarse, si podrían transformarse, si podrían construirse features o si conviene mantenerlos tal cual están.

Modelado

Entrenen distintos modelos de clasificación. Pueden utilizar tanto modelos vistos en clase como otros disponibles en **Scikit-Learn**. Por ejemplo:

- Gaussian Naive Bayes
- Logistic Regression
- Decision Tree
- Random Forest
- Support Vector Machines

Investiguen qué **hiperparámetros pueden ajustarse** en cada modelo y experimenten con diferentes configuraciones. Recuerden lo discutido en clase sobre cómo **SVM escala con la cantidad de features**, especialmente en representaciones de texto.

Evaluación

Definan qué **métrica quieren optimizar** para este problema. Tengan en cuenta que se trata de **clasificación multiclase**. Analicen los resultados de sus modelos y comparen su desempeño.

Entregables

Cada grupo deberá entregar:

1. Un archivo .ipynb que contenga:
    - El análisis exploratorio.
    - El preprocesamiento del texto.
    - La ingeniería de features.
    - El entrenamiento de modelos.
    - La evaluación de resultados.
    - Conclusiones.

    El notebook debe incluir **explicaciones claras de las decisiones tomadas**.

2. Una breve presentación de 20 minutos donde expliquen:
    - Cómo abordaron el problema.
    - Hallazgos encontrados al analizar el Dataset.
    - Qué decisiones tomaron (features, limpieza, etc).
    - Qué funcionó mejor (y que probaron).
    - Qué mejoras implementarían en el futuro.

Importante

- **El notebook debe poder ejecutarse completamente utilizando Run All.**
- Pueden usar herramientas de IA generativa durante el desarrollo del trabajo, siempre que el uso quede explicitado. Incluyan al final del notebook una breve sección indicando en qué partes del proceso las usaron y con qué fin (por ejemplo: entender un mensaje de error, explorar alternativas de preprocesamiento, redactar conclusiones). Lo que se evalúa en este trabajo son las decisiones que toman y la justificación que dan de ellas, no la cantidad de código producido: una solución generada automáticamente que no puedan explicar vale menos que una más simple que entiendan por completo. **Tengan en cuenta que durante la presentación se les van a hacer preguntas sobre cualquier parte del notebook, incluidas las que no hayan escrito ustedes.**